ЛЕКЦИЯ 2

Точечное оценивание и его свойства

Начнем с общей постановки задачи оценивания

Определение. Пусть $X=\left(X_1,\ldots,X_n\right)$ выборка объема n из семейства распределений $\mathcal{F}_\theta$, $\theta\in\Theta$. *Статистикой* (*оценкой*) параметра θ называется произвольная функция $\theta^*=\theta^*\left(X_1,\ldots,X_n\right)$, являющаяся случайной величиной

Замечание. Отметим, что статистика зависит только от выборки, а параметр θ на нее не влияет и в нее не заложен, хотя и служит для оценивания этого самого параметра

Очевидно, что если мы говорим о необходимости оценить параметр θ, то результат такого оценивания должен быть в некотором смысле близок к оцениваемому параметру, иначе смысла в таком оценивании немного. Поэтому надо договориться, что мы будем понимать под этим «близок»

Определение. Статистика $\theta^*=\theta^*\left(X_1,\ldots,X_n\right)$ называется *несмещенной* оценкой параметра θ, если справедливо равенство $\mathrm{E}\,\theta^*=\theta$

Это означает, что «в среднем» наша оценка равна оцениваемому параметру

Несмещенность хорошее свойство, но в природе встречается редко. Чаще удается обеспечить лишь ослабленное свойство асимптотическую несмещенность

Определение. Статистика $\theta^*=\theta^*\left(X_1,\ldots,X_n\right)$ называется *асимптотически несмещенной* оценкой параметра θ, если выполняется $\mathrm{E}\,\theta^*\underset{n\to\infty}{\to}\theta$

Асимптотическая несмещенность это несмещенность в пределе, при неограниченном возрастании выборки. Конечно, несмещенность влечет за собой асимптотическую несмещенность. Обратное, вообще говоря, неверно

Естественным выглядит и следующее требование к «хорошей» оценке

Определение. Статистика $\theta^*=\theta^*\left(X_1,\ldots,X_n\right)$ называется *состоятельной* оценкой параметра θ, если выполняется $\theta^*\overset{\mathrm{P}}{\underset{n\to\infty}{\to}}\theta$

Это означает, что последовательность оценок (зависящая от объема выборки) приближается к неизвестному параметру

Пример

Вернемся, к примеру прошлой лекции об оценивании вероятности $p^*=\dfrac{S_n}{n}$

$$\mathrm{E}\left(\frac{S_n}{n}\right)=\frac{1}{n}\mathrm{E}\,S_n=\frac{np}{n}=p \text{ и } \frac{S_n}{n}\overset{\mathrm{P}}{\underset{n\to\infty}{\to}}p$$

Выполненные выкладки говорят о том, что предложенная оценка вероятности является несмещенной и состоятельной

Оценивание выборочных моментов

Ранее уже говорилось, что поскольку эмпирическая ФР строится также как ФР дискретной СВ, принимающей значения $X_1,\ldots,X_n$ с равными вероятностями $\dfrac{1}{n}$, то возможно и выборочные моменты можно рассчитывать по формулам для дискретной СВ

Определение. *Выборочным средним* $\overline{X}$ (*выборочным матожиданием* $\overline{m}$) называется СВ

$$\overline{X}=\frac{X_1+\ldots+X_n}{n}=\frac{1}{n}\sum_{i=1}^{n}X_i$$

Выборочное среднее логично считать оценкой математического ожидания. Покажем, насколько это так

Будем полагать, что все элементы выборки $X=\left(X_1,\ldots,X_n\right)$ извлечены из одной генеральной совокупности ξ, и что $\mathrm{E}\,X_i=\mathrm{E}\,\xi=\mu$, $\mathrm{D}\,X_i=\mathrm{D}\,\xi=\sigma^2$ и они конечны

Пример

Рассмотрим рост 5 студентов: $X=\left(168,172,175,180,185\right)$

Оценка среднего роста $\overline{X} = \dfrac{168+172+175+180+185}{5} = 176$

Иллюстрация 1

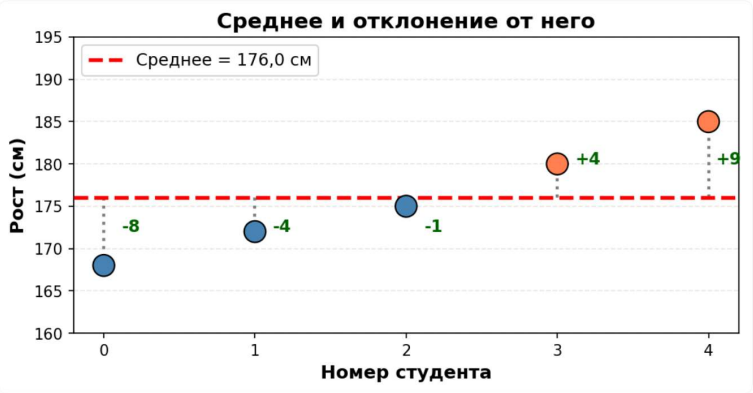

Теорема. (свойства среднего) Выборочное среднее обладает следующими свойствами:

(1) $\mathrm{E}\,\overline{X} = \mu$, т. е. является несмещенной оценкой МО

(2) $\overline{X} \xrightarrow[n\to\infty]{\mathrm{P}} \mu$, т. е. является состоятельной оценкой МО

(3) $Y_n = \sqrt{n}\dfrac{\overline{X}-\mu}{\sigma} \xrightarrow[n\to\infty]{d} Y \sim \mathrm{N}_{0,1}$, т. е. является асимптотически нормальной оценкой МО

Доказательство:

(1) $\mathrm{E}\,\overline{X} = \mathrm{E}\left(\dfrac{X_1+\ldots+X_n}{n}\right) = \dfrac{1}{n}\mathrm{E}\sum_{i=1}^{n} X_i = \dfrac{1}{n}\sum_{i=1}^{n}\mathrm{E}\,X_i = \dfrac{n\mu}{n} = \mu$

(2) Следует из ЗБЧ Чебышёва

(3) Следует из ЦПТ

Определение. *Выборочным моментом k-го порядка* называется СВ

$$\overline{X^k} = \frac{X_1^k+\ldots+X_n^k}{n} = \frac{1}{n}\sum_{i=1}^{n} X_i^k$$

Для выборочных моментов k-го порядка формулируется и доказывается аналогичная теорема о свойствах

Перейдем к рассмотрению центрального момента 2-го порядка – дисперсии

Определение. *Выборочной дисперсией* называется СВ

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

Пример

Для примера с ростом студентов посчитаем выборочную дисперсию

$$S^2 = \frac{178}{5} = 35{,}6 \Rightarrow S = 5{,}97$$

Иллюстрация 2

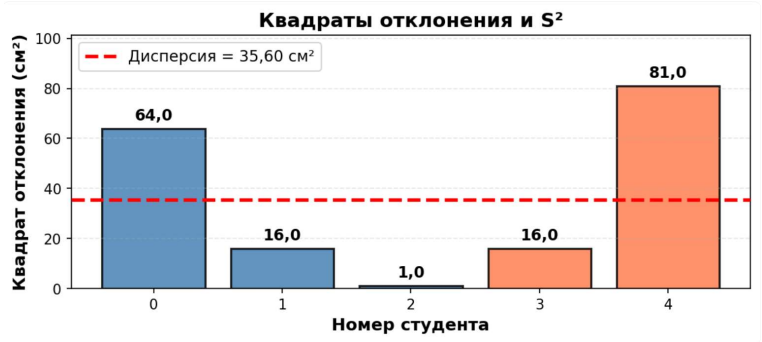

Иллюстрация 3

Построим интервал $\left[\overline{X}-S;\overline{X}+S\right]$ показывающий «типичный» разброс данных вокруг среднего

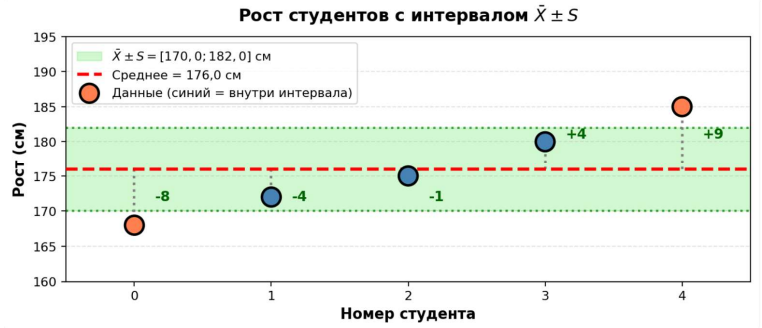

Для нормального распределения 68% наблюдений попадает в интервал $\left[\overline{X}-S;\overline{X}+S\right]$

В нашем случае 60%, но ведь и объем выборки небольшой

Убедимся, что и для выборочной величины справедлива формула известная нам из ТВ

Теорема. Для выборочной дисперсии справедливо соотношение
$S^2 = \overline{X^2} - \overline{X}^2$

Доказательство:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2 = \frac{1}{n}\sum_{i=1}^{n}\left(X_i^2 - 2X_i\overline{X} + \overline{X}^2\right) =$$

$$= \frac{1}{n}\sum_{i=1}^{n}X_i^2 - 2\overline{X}\frac{1}{n}\sum_{i=1}^{n}X_i + \overline{X}^2 = \overline{X^2} - 2\overline{X}^2 + \overline{X}^2 = \overline{X^2} - \overline{X}^2$$

Сформулируем в виде теоремы свойства выборочной дисперсии, имея в виду сказанное ранее, что $\mathrm{D}X_i = \sigma^2$ и конечна

Теорема. Выборочная дисперсия обладает следующими свойствами:

(1) S^2 смещенная оценка дисперсии, а именно $\mathrm{E}S^2 = \frac{n-1}{n}\sigma^2$

(2) $S^2 \xrightarrow[n\to\infty]{\mathrm{P}} \sigma^2$, т. е. является состоятельной оценкой дисперсии

Доказательство:

Остановимся на доказательстве только первого утверждения

$$\mathrm{E}S^2 = \mathrm{E}\overline{X^2} - \mathrm{E}\overline{X}^2 = \mathrm{E}\left(\frac{X_1^2 + \ldots + X_n^2}{n}\right) - \mathrm{E}\left(\frac{X_1 + \ldots + X_n}{n}\right)^2$$

Первое слагаемое $\mathrm{E}\left(\frac{X_1^2 + \ldots + X_n^2}{n}\right) = \frac{1}{n}\mathrm{E}\left(X_1^2 + \ldots + X_n^2\right) = \mathrm{E}X_1^2$

Второе слагаемое $\mathrm{E}\left(\frac{X_1 + \ldots + X_n}{n}\right)^2 = \mathrm{E}\sum_{i=1}^{n}\frac{X_i^2}{n^2} + 2\mathrm{E}\sum_{i<j}^{n}\frac{X_iX_j}{n^2} =$

$$= \frac{1}{n^2}\left(\mathrm{E}\sum_{i=1}^{n}X_i^2 + 2\mathrm{E}\sum_{i<j}^{n}X_iX_j\right) \underset{\text{из независ}}{=} \frac{\mathrm{E}X_1^2}{n} + \frac{2}{n^2}\sum_{i<j}^{n}\left(\mathrm{E}X_1\right)^2 =$$

В сумме $\frac{n(n-1)}{2}$ слагаемых. Поэтому

$$\mathrm{E}\left(\frac{X_1 + \ldots + X_n}{n}\right)^2 = \frac{1}{n}\mathrm{E}X_1^2 + \frac{n-1}{n}\left(\mathrm{E}X_1\right)^2$$

Тогда

$$\mathrm{E}S^2 = \mathrm{E}X_1^2 - \frac{1}{n}\mathrm{E}X_1^2 - \frac{n-1}{n}\left(\mathrm{E}X_1\right)^2 = \frac{n-1}{n}\left(\mathrm{E}X_1^2 - \left(\mathrm{E}X_1\right)^2\right) = \frac{n-1}{n}\mathrm{D}X_1$$

Определение. *Несмещенной выборочной дисперсией* называется СВ

$$\overline{\sigma^2} = \frac{n}{n-1}S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

Замечание. Естественно, что заметной такая корректировка будет только для небольших выборок

Пример

Для роста студентов $\overline{\sigma^2} = \frac{178}{4} = 44{,}5 \Rightarrow S = 6{,}67$. Отклонение $\overline{\sigma^2}$ и S^2 существенное

<u>Иллюстрация 4</u>

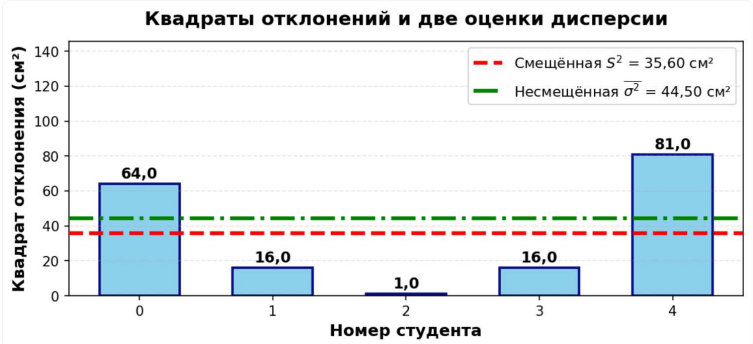

Другие характеристики выборки

Определение. Пусть выборка $X = \left(X_1, \ldots, X_n\right)$ извлечена из генеральной совокупности ξ. *Выборочной модой* $\overline{m}_0$ для выборки $X = \left(X_1, \ldots, X_n\right)$ называется чаще всего наблюдаемое значение, т. е.

$$n_i\left(\overline{m}_0\right) = \max_i n_i$$

В случае дискретных СВ оценка моды – это конкретное значение из выборки с максимальной частотой появления

При рассмотрении непрерывных данных, когда строится гистограмма распределения можно указать лишь модальный интервал – интервал с максимальной частотой попаданий (с самым высоким столбцом), а не точное значение моды

Отметим, что

- Ширина интервала в гистограммы может сместить «самый высокий столбец»
- Выборка может иметь несколько мод

Пример

Рассматриваем тот же пример с ростом студентов (некоторые значения немного изменены для наглядности). Модальные интервалы меняются в зависимости от выбора длины интервала гистограммы

<u>Иллюстрация 5</u>

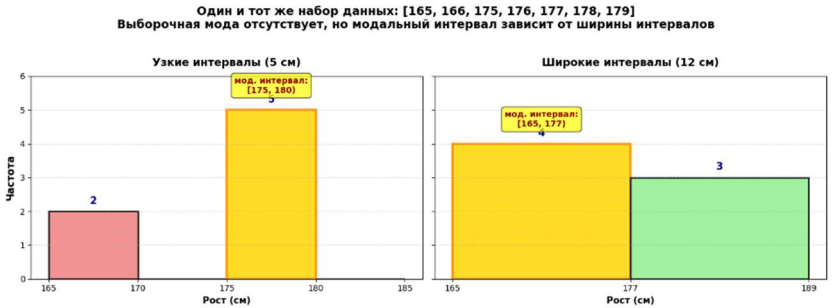

Пример

(1) $X=(2,3,3,4,5,3,3)$ – унимодальная выборка

(2) $X=(1,1,2,3,4,4,4,1,4)$ – бимодальная выборка

(3) $X=(168,172,175,180,185)$ – мода отсутствует, каждое значение уникально

<u>Иллюстрация 6</u>

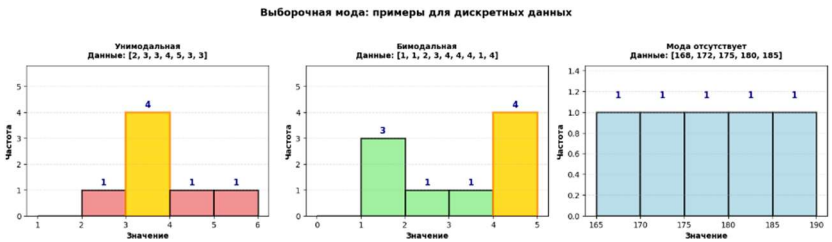

Определение. Пусть выборка $X=(X_1,\ldots,X_n)$ извлечена из генеральной совокупности ξ. *Выборочной медианой* $\overline{m}_e$ для выборки $X=(X_1,\ldots,X_n)$ называют число

$$\overline{m}_e=\begin{cases} X_{\frac{n+1}{2}}, n-\text{нечетное} \\ \dfrac{X_{\frac{n}{2}}+X_{\frac{n+1}{2}}}{2}, n-\text{четное} \end{cases}$$

Отметим, что

- медиана интуитивно понятна как «середина» данных
- существует для любых данных
- в отличии от среднего «не реагирует» на выбросы данных

Пример

При нечетном $n=7$, $X=(168,172,175,180,185,162,178)$ выбираем среднее значение $\overline{m}_e=175$

При четном $n=6$, $X=(165,170,172,175,180,188)$ находим полусумму двух средних $\overline{m}_e=\dfrac{172+175}{2}=173,5$

<u>Иллюстрация 7</u>

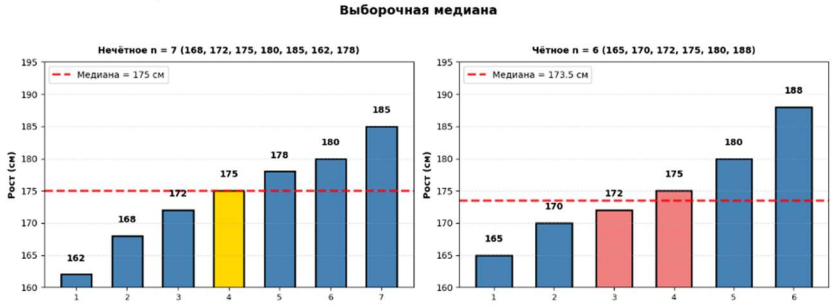

Пример

Сравним выборочное среднее и медиану при различных исходных данных (рост студентов)

(1) обычные данные $X=(168,172,175,180,185)$, $\overline{X}=176$, $\overline{m}_e=175$

(2) данные с выбросом $X=(168,172,175,180,250)$, $\overline{X}=189$, $\overline{m}_e=175$

<u>Иллюстрация 8</u>

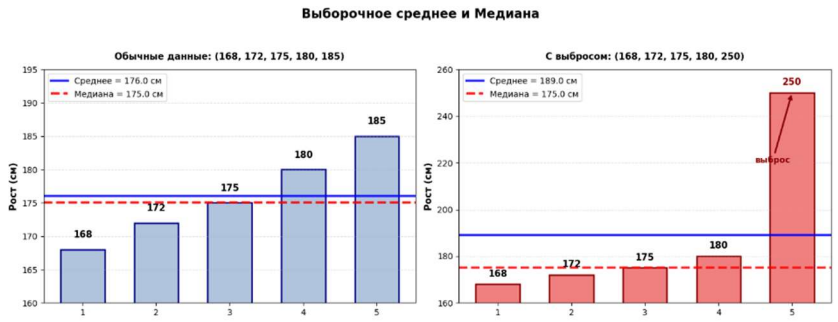

Определение. Пусть выборка $X=(X_1,\ldots,X_n)$ извлечена из генеральной совокупности ξ. *Выборочной квантилью* уровня $\alpha\in(0,1)$ для выборки $X=(X_1,\ldots,X_n)$ называют число

$$\overline{x}_\alpha=\begin{cases}X_{[n\alpha]+1}, n\alpha\notin\mathbb{Z}\\ \dfrac{X_{n\alpha}+X_{n\alpha+1}}{2}, n\alpha\in\mathbb{Z}\end{cases}$$

Замечание. Квантиль уровня $\alpha=0,5$ является медианой

Квантиль – это «рубеж», который делит упорядоченные выборочные данные на части по количеству наблюдений, а не по их значениям
Квантили отвечают на вопрос:
«Какое значение отделяет нижние p% данных от верхних (100−p)%?»

Квантили важны, потому что

- выбросы искажают выборочное среднее, а квантили не зависят от экстремальных значений
- 5%- и 95% квантили показывают границы типичных значений

Квантили превращают сложное распределение в простые ориентиры:

- Где начинается «низкий» рост?
- Где заканчивается «средний» доход?
- Какова граница «крайне высоких» значений?

Это делает их незаменимыми для анализа данных в медицине, экономике, образовании

Пример

Рост студентов (выборка увеличена для большей наглядности)
$X=(162,165,168,170,172,174,176,178,180,183,186,190)$

Квантиль 10% – какой рост у самого низкого десятка процентов? – 10% студентов имеют рост ниже 166 см
Квантиль 50% (медиана) – кто находится ровно посередине? – половина студентов ниже, п выше 175 см
Квантиль 10% – начиная с какого роста идут самые высокие 10%? – 10% студентов выше 185 см
Каждый квантиль — это «место в этой очереди», а не конкретный сантиметр
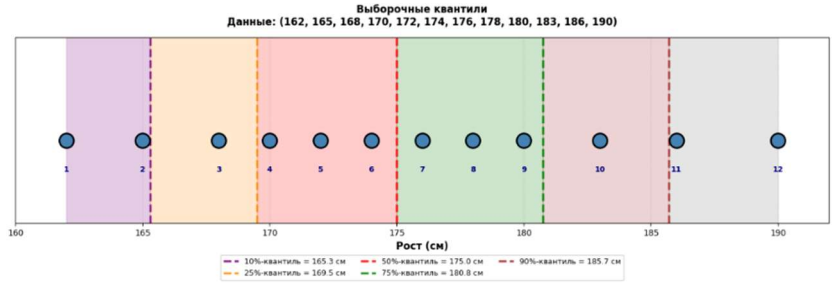
<u>Иллюстрация 9</u>