ЛЕКЦИЯ 7

Некоторые распределения, используемые в статистике

Изучим некоторые абсолютно непрерывные распределения, тесно связанные с нормальным

Гамма-распределение

В этом пункте нам понадобятся многие знания, полученные в теории вероятностей. Перед тем, как сформулировать определение гамма-распределения, напомним определение одной из важных функций, так называемой гамма-функции Эйлера

Определение. Гамма-функцией Эйлера называется функция

$$\Gamma(\lambda)=\int_0^{+\infty} t^{\lambda-1}e^{-t}dt$$

Замечание. Нам достаточно будет рассматривать гамма-функцию при $\lambda>0$

При таких λ интеграл сходится

Замечание. Отметим также, что при $\lambda>0$ функция обладает свойством $\Gamma(\lambda+1)=\lambda\Gamma(\lambda)$

Лемма. $\Gamma\left(\frac{1}{2}\right)=\sqrt{\pi}$

Доказательство:

$$\Gamma\left(\frac{1}{2}\right)=\int_0^{+\infty}\frac{e^{-t}}{\sqrt{t}}dt=\left[\sqrt{t}=z, dz=\frac{dt}{2\sqrt{t}}\right]=2\int_0^{+\infty}e^{-z^2}dz=2\cdot\frac{\sqrt{\pi}}{2}=\sqrt{\pi}$$ (использовали интеграл Эйлера-Пуассона)

Определение. Говорят, что случайная величина ξ имеет гамма-распределение с параметрами $\alpha>0, \lambda>0$, и пишут $\xi\sim\Gamma_{\alpha,\lambda}$, если ее плотность имеет вид $f_\xi(t)=\begin{cases}0, t<0\\ \frac{\alpha^\lambda}{\Gamma(\lambda)}t^{\lambda-1}e^{-\alpha t}, t\geq 0\end{cases}$

То, что введенная функция является плотностью распределения, проверяется непосредственно с использованием замены $z=\alpha t$

Кроме того, легко видеть, что при $\lambda=1$ гамма-распределение превращается в экспоненциальное распределение с параметром α

<u>Иллюстрация 1</u>

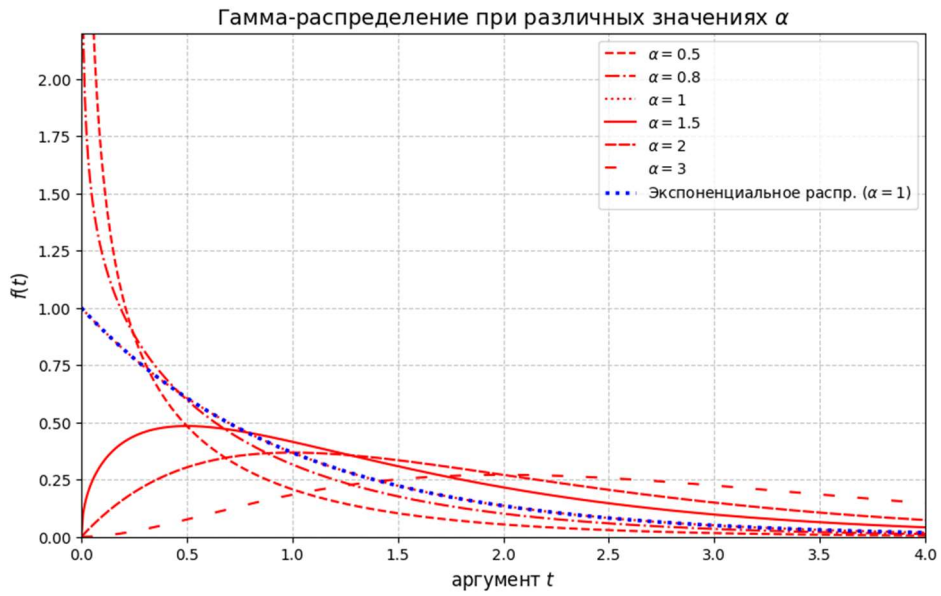

<u>Иллюстрация 2</u>

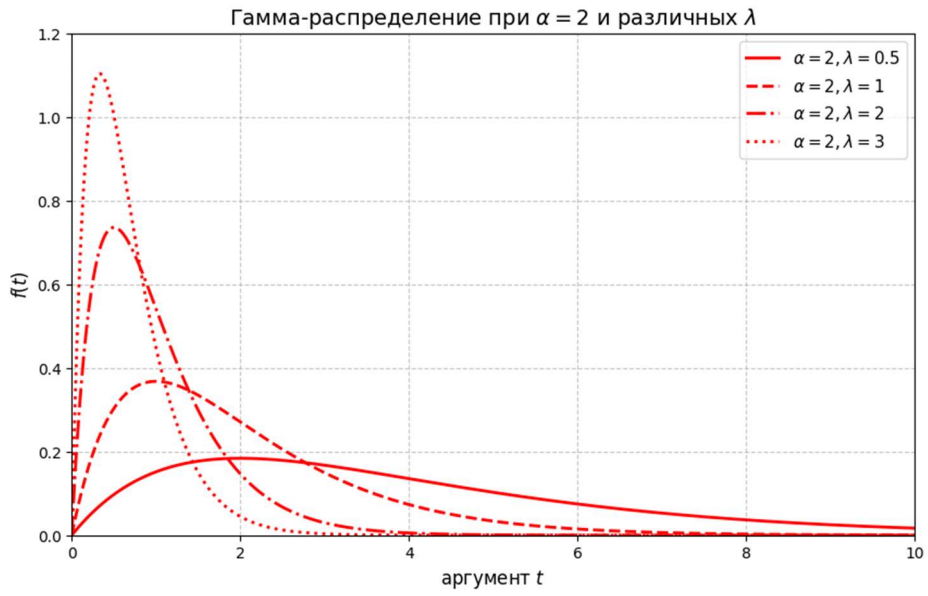

- *Параметр α отвечает за форму кривой: определяет, будет ли она убывающей (как экспонента) или иметь колоколообразный вид с пиком*
- *Параметр λ отвечает за масштаб: определяет, насколько быстро происходит процесс. Он сжимает или растягивает кривую вдоль оси, не меняя её принципиальной формы*

Сформулируем без доказательства леммы, которая понадобится нам для введения следующего важного распределения

Лемма. Пусть $\xi_1 \sim \Gamma_{\alpha,\lambda_1}, \xi_2 \sim \Gamma_{\alpha,\lambda_2}$ две независимые случайные величины. Тогда $\xi_1 + \xi_2 \sim \Gamma_{\alpha,\lambda_1+\lambda_2}$

Лемма. Пусть случайные величины $\xi_1, \xi_2, \ldots, \xi_n$ независимые в совокупности, причем $\xi_i \sim \Gamma_{\alpha,\lambda_i}, i \in \{1, 2, \ldots, n\}$.

Тогда $S_n = \xi_1 + \xi_2 + \ldots + \xi_n \sim \Gamma_{\alpha,\lambda_1+\lambda_2+\ldots+\lambda_n}$

Лемма. Пусть случайная величина $\xi \sim \mathrm{N}_{0,1}$. Тогда ξ^2 имеет распределение $\Gamma_{\frac{1}{2},\frac{1}{2}}$

Распределение χ^2 Пирсона

Из приведенных выше лемм следует следующее утверждение

Лемма. Если случайные величины $\xi_1, \xi_2, \ldots, \xi_n$ независимые в совокупности и имеют стандартное нормальное распределение $\mathrm{N}_{0,1}$, то случайная величина $\chi_k^2 = \xi_1^2 + \xi_2^2 + \ldots + \xi_n^2$ имеет распределение $\Gamma_{\frac{1}{2},\frac{k}{2}}$

Определение. Распределение суммы квадратов k независимых в совокупности случайных величин со стандартным нормальным распределением называется распределением «хи-квадрат» χ^2 с k степенями свободы и обозначается H_k

Т. к. $\mathrm{H}_k = \Gamma_{\frac{1}{2},\frac{k}{2}}$, то плотность имеет вид $f_{\chi^2}(t) = \begin{cases} 0, t < 0 \\ \dfrac{1}{2^{\frac{k}{2}}} \cdot \dfrac{\alpha^\lambda}{\Gamma\left(\dfrac{k}{2}\right)} t^{\frac{k}{2}-1} e^{-\frac{t}{2}}, t \geq 0 \end{cases}$

<u>Иллюстрация 3</u>

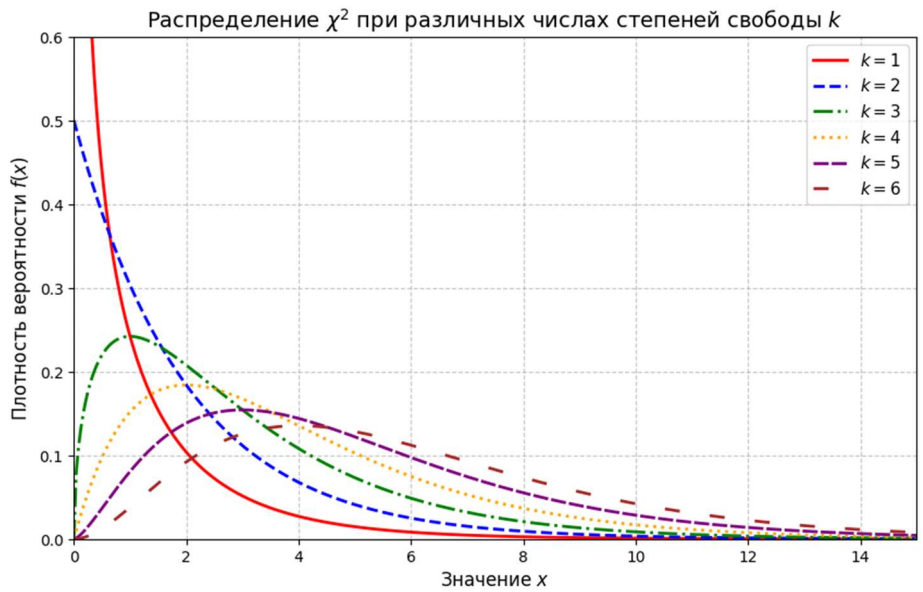

Лемма. Пусть $\chi_k^2 \sim \mathrm{H}_k, \chi_m^2 \sim \mathrm{H}_m$ две независимые случайные величины. Тогда $\chi_{k+m}^2 = \chi_k^2 + \chi_m^2 \sim \mathrm{H}_{k+m}$

Доказательство:

Т. к. $\chi_k^2 \sim \mathrm{H}_k = \Gamma_{\frac{1}{2},\frac{k}{2}}, \chi_m^2 \sim \mathrm{H}_m = \Gamma_{\frac{1}{2},\frac{m}{2}}$ и они независимы, то, согласно соответствующей лемме, о гамма-распределениях имеем

$\chi_k^2 + \chi_m^2 = \Gamma_{\frac{1}{2},\frac{k+m}{2}} = \mathrm{H}_{k+m}$

Вычислим моменты этого распределения

Лемма. Пусть $\chi_k^2 \sim \mathrm{H}_k$. Тогда $\mathrm{E}\,\chi_k^2 = k, \mathrm{D}\,\chi_k^2 = 2k$

Доказательство:

Если $\xi_1 \sim \mathrm{N}_{0,1}$, то, $\mathrm{E}\,\xi_1^2 = 1, \mathrm{D}\,\xi_1^2 = \mathrm{E}\,\xi_1^4 - \left(\mathrm{E}\,\xi_1^2\right)^2 = 2$

По свойства математического ожидания и дисперсии

$\mathrm{E}\,\chi_k^2 = \mathrm{E}\left(\xi_1^2 + \xi_2^2 + \ldots + \xi_n^2\right) = k\,\mathrm{E}\,\xi_1^2 = k$

$$\mathrm{D}\,\chi_k^2 = \mathrm{D}\left(\xi_1^2 + \xi_2^2 + \ldots + \xi_n^2\right) = k\,\mathrm{D}\,\xi_1^2 = 2k$$

Лемма. Пусть случайные величины $\xi_1, \xi_2, \ldots, \xi_n$ независимые в совокупности и имеют распределение $\mathrm{N}_{\mu,\sigma}$, тогда случайная величина $\chi_k^2 = \sum_{i=1}^{k}\left(\frac{\xi_i - \mu}{\sigma}\right)^2$ имеет распределение H_k

Доказательство:

Если $\xi_i \sim \mathrm{N}_{\mu,\sigma} \Rightarrow \frac{\xi_i - \mu}{\sigma} \sim \mathrm{N}_{0,1}$, то $\mathrm{E}\,\xi_1^2 = 1, \mathrm{D}\,\xi_1^2 = \mathrm{E}\,\xi_1^4 - \left(\mathrm{E}\,\xi_1^2\right)^2 = 2$

Распределение Стьюдента

Определение. Пусть случайные величины $\xi_0, \xi_1, \xi_2, \ldots, \xi_k$ независимы в совокупности и имеют со стандартное нормальное распределение $\mathrm{N}_{0,1}$. Распределение случайной величины

$t_k = \frac{\xi_0}{\sqrt{\frac{1}{k}\left(\xi_1^2 + \xi_2^2 + \ldots + \xi_k^2\right)}} = \frac{\xi_0}{\sqrt{\frac{\chi_k^2}{k}}}$ называется распределением Стьюдента с k степенями свободы и обозначается T_k

Можно показать, что что плотность случайной величины, имеющей распределение Стьюдента, равна

$$f_{t_k}(t) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{\pi k}\,\Gamma\left(\frac{k}{2}\right)}\left(1 + \frac{t^2}{k}\right)^{-\frac{k+1}{2}}$$

<u>Иллюстрация 4</u>

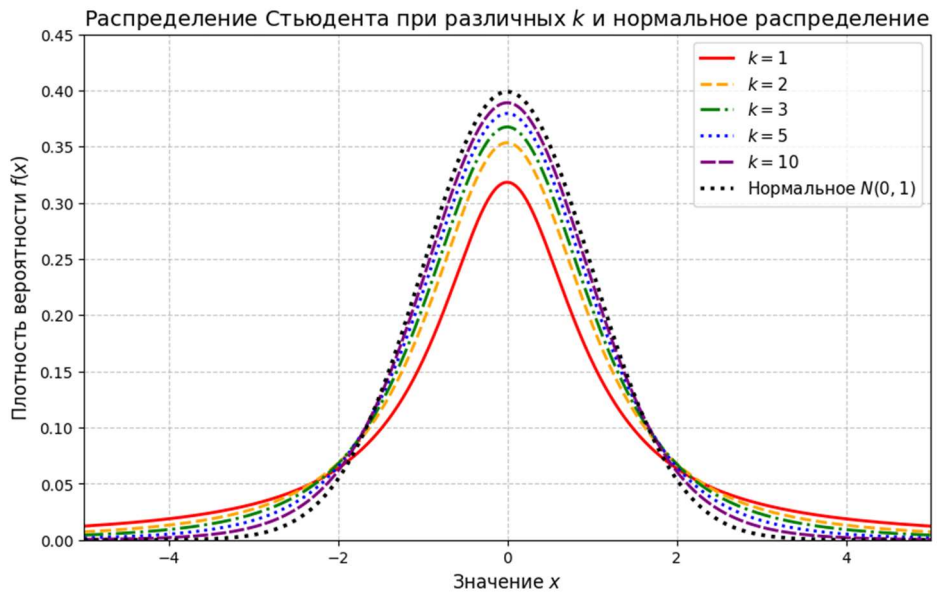

Лемма. Пусть случайная величина t_k имеет распределение Стьюдента T_k с k степенями свободы. Тогда случайная величина $-t_k$ тоже имеет распределение Стьюдента T_k с k степенями свободы

Доказательство:

$$F_{-t_k}(x) = \mathrm{P}\left(-t_k < x\right) = \mathrm{P}\left(t_k > -x\right) = \int_{-x}^{+\infty} f_{t_k}(t)\,dt$$

Сделаем замену $p = -t$. Тогда в силу четности $f_{t_k}(t)$ получим

$$F_{-t_k}(x) = -\int_{x}^{-\infty} f_{t_k}(-p)\,dp = -\int_{-\infty}^{x} f_{t_k}(p)\,dp = F_{t_k}(x)$$

Лемма. Распределение Стьюдента T_k слабо сходится к стандартному нормальному распределению $\mathrm{N}_{0,1}$ при $k \to +\infty$

Доказательство:

Пусть случайные величины $\xi_0, \xi_1, \xi_2, \ldots, \xi_k$ независимы в совокупности и имеют со стандартное нормальное распределение $\mathrm{N}_{0,1}$. Как уже было отмечено $\mathrm{E}\,\xi_1^2 = 1$, а тогда, по закону больших чисел

$$\frac{\chi_k^2}{k} = \frac{\xi_1^2 + \xi_2^2 + \ldots + \xi_n^2}{k} \xrightarrow[k\to\infty]{\mathrm{P}} 1$$

Но тогда, согласно свойствам сходимости по вероятности,

$$t_k = \frac{\xi_0}{\sqrt{\frac{\chi_k^2}{k}}} \xrightarrow[k\to\infty]{\mathrm{P}} \xi_0$$

откуда и следует слабая сходимость. Т. е.

$$t_k \xrightarrow[k\to\infty]{d} \xi_0 \sim \mathrm{N}_{0,1}$$

Распределение Фишера

Распределение Фишера тесно связано с теми распределениями, что мы только что рассмотрели, но не связано с задачами, решаемыми в ближайших лекциях. Мы будем использовать распределение Фишера при решении задач проверки гипотез

Определение. Пусть независимые случайные величины $\xi \sim \mathrm{H}_{k_1}, \eta \sim \mathrm{H}_{k_2}$. Тогда распределение случайной величины $\mathrm{F}_{k_1,k_2} = \dfrac{\xi/k_1}{\eta/k_2}$ называется распределением Фишера с k_1 и k_2 степенями свободы

<u>Иллюстрация 5</u>

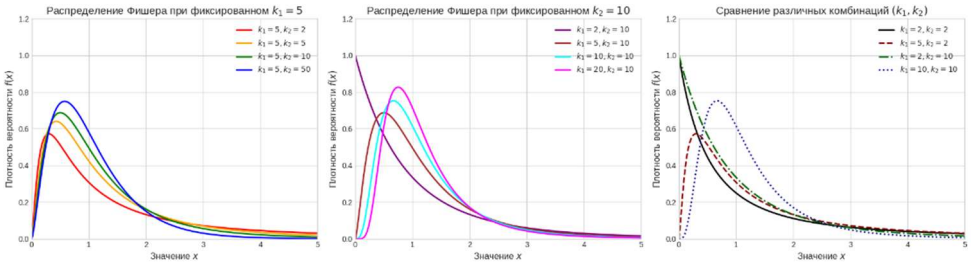

Отметим без доказательства свойство

Лемма. Если случайная величина имеет распределение Стьюдента с k степенями свободы T_k, то её квадрат имеет распределение Фишера с параметрами $1, k$, т. е. $\mathrm{T}_k^2 \sim \mathrm{F}_{1,k}$

Теперь можно переходить к обсуждению интервального оценивания

Интервальное оценивание

В предыдущих лекциях мы поговорили про так называемое точечное оценивание неизвестных параметров генеральной совокупности. Нами были изучены методы моментов и максимального правдоподобия для получения этих оценок, а также было сказано несколько слов про их свойства: несмещенность, состоятельность, асимптотическую нормальность. Более того, мы немного пролили свет на то, как можно сравнивать оценки, определили понятие эффективной. Однако, точечное оценивание – не единственно возможный вариант. В следующих двух лекциях мы займемся так называемым интервальным оцениванием – построением доверительных интервалов, в которых, с наперед заданной вероятностью, содержится интересующая нас величина

Точные доверительные интервалы

Пусть у нас, как обычно, имеется выборка $X_1, \ldots, X_n$ из семейства распределений $\mathcal{F}_\theta$, которое известным образом зависит от неизвестного параметра θ из некоторого множества Θ

Определение. Пусть $0 < \varepsilon < 1$.

Интервал $\left(\theta^-; \theta^+\right) = \left(\theta^-\left(X, \varepsilon\right); \theta^+\left(X, \varepsilon\right)\right)$, где θ^-, θ^+ – статистики, называется доверительным интервалом уровня доверия (или надежности) $1-\varepsilon$, если для любого $\theta \in \Theta$ выполняется $\mathrm{P}_\theta\left(\theta^- < \theta < \theta^+\right) \geq 1 - \varepsilon$

Итак, доверительный интервал уровня доверия $1-\varepsilon$ – это интервал, который с вероятностью не меньше, чем $1-\varepsilon$, накрывает (содержит) интересующий нас параметр

Замечание. Почему берется неравенство, а не просто равенство? Действительно, для абсолютно непрерывных распределений вопрос о вероятности, равной $1-\varepsilon$, имеет место для любого $\varepsilon \in (0;1)$, т. к. каждая такая вероятность достигается хотя бы потому, что функция

распределения абсолютно непрерывного распределения непрерывна.

Ситуация совершенно меняется в случае, если рассматривается дискретное распределение. Скажем, для случайной величины ξ с распределением Бернулли $\mathrm{B}_{0,5}$ с параметром $p=0,5$, равенство $\mathrm{P}\left(a<\xi<b\right)=0,75$ невозможно в принципе ни для каких $a,b\in\mathbb{R}$. При этом если заменить равенство на неравенство $\geq$, все становится вполне осмысленным

Определение. Если в определении доверительного интервала вместо неравенства достигается равенство, т. е. $\mathrm{P}_\theta\left(\theta^-<\theta<\theta^+\right)=1-\varepsilon$, то доверительный интервал называется точным

Замечание. Ясно, что тем доверительный интервал лучше, чем он уже. Да и вообще, конструкция оправдана, если только $\theta^+-\theta^-\underset{n\to\infty}{\overset{\mathrm{P}}{\to}}0$, т. е. если длина интервала с ростом значений n стремится к нулю (по вероятности)

Построение точных доверительных интервалов – дело непростое

Приведем пример, иллюстрирующий общую идею этого построения

Точный доверительный интервал для $\mathrm{U}_{0,\theta}$ при известной дисперсии

Пусть $X_1,\ldots,X_n\sim\mathrm{U}_{0,\theta}$ (имеет равномерное распределение), где параметр θ неизвестен и $\theta\in\Theta=\left(0;+\infty\right)$

Для этого рассмотрим вспомогательные случайные величины $Y_i=\dfrac{X_i}{\theta}$.

Согласно свойствам линейных преобразований от случайных величин, новые случайные величины имеют равномерное распределение $\mathrm{U}_{0,1}$. В частности, важно то, что их распределение теперь не зависит от θ

Распределение n-ой порядковой статистики имеет распределение

$$F_{Y^{(n)}}\left(t\right)=\begin{cases}0,t\leq 0\\ t^n,0<t\leq 1\\ 1,t>1\end{cases}$$

Найдем левую границу x интервала $\left(x,1\right)$, для которого $\mathrm{P}_\theta\left(x<Y^{(n)}<1\right)=1-\varepsilon$

Это легко сделать, используя функцию распределения, ведь по уму $x>0$, т. к. $Y^{(n)}\sim\mathrm{U}_{0,1}$ и $\mathrm{P}_\theta\left(x<Y^{(n)}<1\right)=F_{Y^{(n)}}\left(1\right)-F_{Y^{(n)}}\left(x\right)=1-x^n$

Приравняв выражения, получим

$1-x^n=1-\varepsilon\Leftrightarrow x^n=\varepsilon\Leftrightarrow x=\sqrt[n]{\varepsilon}$

Значит, $\mathrm{P}_\theta\left(\sqrt[n]{\varepsilon}<Y^{(n)}<1\right)=1-\varepsilon$

Подставив вместо порядковой статистики $Y^{(n)}$ ее выражение $Y^{(n)}=\dfrac{X^{(n)}}{\theta}$ и учитывая положительность θ и $X^{(n)}$ получаем

$$1-\varepsilon=\mathrm{P}_\theta\left(\sqrt[n]{\varepsilon}<Y^{(n)}<1\right)=\mathrm{P}_\theta\left(\sqrt[n]{\varepsilon}<\frac{X^{(n)}}{\theta}<1\right)=\mathrm{P}_\theta\left(X^{(n)}<\theta<\frac{X^{(n)}}{\sqrt[n]{\varepsilon}}\right)$$

Значит, интервал $\left(\theta^-\left(X,\varepsilon\right);\theta^+\left(X,\varepsilon\right)\right)=\left(X^{(n)}<\theta<\dfrac{X^{(n)}}{\sqrt[n]{\varepsilon}}\right)$

Обсудим вопрос стремления интервала к нулю при $n\to\infty$

Т. к. $\sqrt[n]{\varepsilon}\underset{n\to\infty}{\to}1$, то согласно формуле Тейлора

$$1-\frac{1}{\sqrt[n]{\varepsilon}}=1-\varepsilon^{-\frac{1}{n}}=1+\frac{1}{n}\ln\varepsilon+o\left(\frac{1}{n^2}\right)$$

Т. е. скорость стремления к 0 имеет порядок $\dfrac{1}{n}$

Протестируем полученный интервал численно

<u>Иллюстрация 6</u>

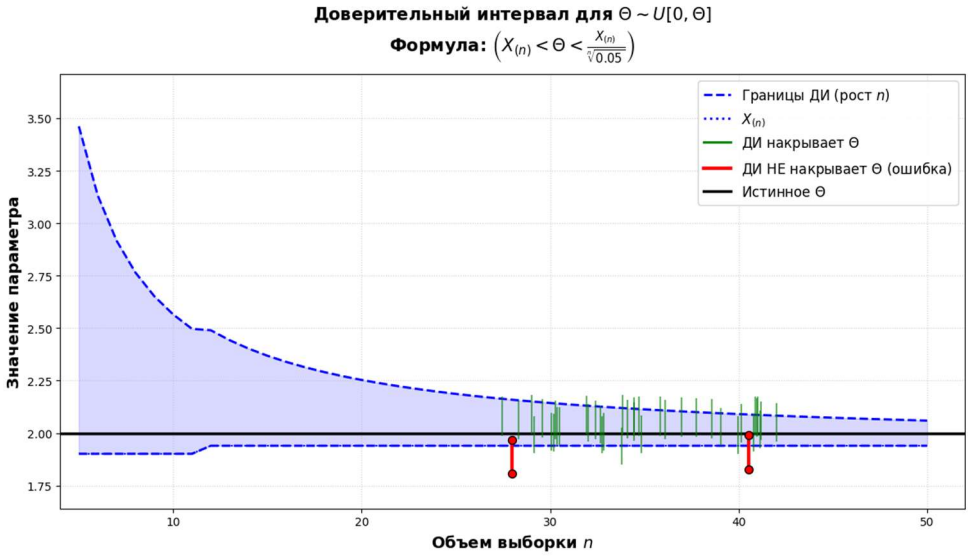

Общий принцип построения доверительных интервалов

Итак, общий принцип построения точных доверительных интервалов можно сформулировать в следующем виде:

1. Составляется случайная величина $T(X,\theta)$, распределение которой не зависит от параметра θ, и которая обратима по θ при фиксированной выборке X;
2. Находятся квантили t_1 и t_2 распределения случайной величины T так, чтобы выполнялось равенство
$$\mathrm{P}_\theta\left(t_1 < T(X,\theta) < t_2\right) = 1-\varepsilon$$
3. Неравенство $t_1 < T(X,\theta) < t_2$ р разрешается относительно θ, откуда и получается интересующий нас доверительный интервал

Несмотря на четкий алгоритм действий, сложность описанного подхода достаточно очевидна: совершенно непонятно, как найти «достойную» функцию $T(X,\theta)$, удовлетворяющую описанным условиям. В частности, как ее заставить не зависеть от θ? Именно поэтому, а еще из-за предельных теорем, чаще строят так называемые асимптотические доверительные интервалы, о которых и пойдет речь далее