

Лабораторная работа по математической статистике: «Простая линейная регрессия»

Оценивание функции регрессии и построение доверительных интервалов
для студентов 2 курса

Цель работы

Цель работы — освоить методы оценивания параметров простой линейной регрессии, построения доверительных интервалов для коэффициентов регрессии и доверительного интервала для средней функции регрессии.

В ходе работы студент должен самостоятельно выполнить все вычисления и построения. HTML-генератор используется только для получения исходного набора данных по номеру варианта.

1. Исходная модель

Рассматривается модель простой линейной регрессии:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

где x_i — значение объясняющей переменной, y_i — значение зависимой переменной, β_0 и β_1 — неизвестные параметры модели, ε_i — случайная ошибка.

Оценённая модель имеет вид:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i.$$

2. Получение данных

Для получения данных студент открывает файл `CW4_generator.html`, вводит номер своего варианта и скачивает CSV-файл с исходными данными.

После выбора варианта генератор:

1. показывает набор данных по номеру варианта;
2. сообщает общее количество наблюдений;
3. позволяет скачать полный набор данных в CSV-файл.

Например, для варианта 7 будет создан файл:

`variant_7_data.csv`.

Файл содержит три столбца:

i	x_i	y_i
1	...	...
2	...	...
$\vdots$	$\vdots$	$\vdots$

3. Задание

Для своего варианта необходимо выполнить следующие действия.

3.1. Загрузка данных

Загрузить CSV-файл своего варианта и вывести таблицу исходных данных.

3.2. Диаграмма рассеяния

Построить график зависимости y от x . По графику сделать предварительный вывод о характере зависимости между переменными.

3.3. Оценивание коэффициентов регрессии

Найти оценки коэффициентов простой линейной регрессии:

$$\hat{\beta}_0, \quad \hat{\beta}_1.$$

Записать полученное уравнение регрессии:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

3.4. Расчёт прогнозных значений и остатков

Для каждого наблюдения вычислить прогнозное значение $\hat{y}_i$ и остаток e_i .

Составить таблицу:

i	x_i	y_i	$\hat{y}_i$	e_i
1				
2				
$\vdots$				

3.5. Оценка дисперсии ошибки

Вычислить остаточную сумму квадратов, оценку дисперсии случайной ошибки и остаточное стандартное отклонение.

3.6. Доверительные интервалы для коэффициентов

Построить 95% доверительные интервалы для коэффициентов β_0 и β_1 . Сделать вывод о значимости коэффициента β_1 .

3.7. Доверительный интервал для функции регрессии

Построить 95% доверительный интервал для средней функции регрессии $\mathbb{E}(Y \mid x)$.

На одном графике необходимо изобразить:

1. исходные точки (x_i, y_i) ;
2. оценённую прямую регрессии;
3. нижнюю границу доверительного интервала для функции регрессии;
4. верхнюю границу доверительного интервала для функции регрессии.

4. Формулы для расчётов

4.1. Средние значения

Вычислить выборочные средние:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

4.2. Вспомогательные суммы

Вычислить:

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2,$$
$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

4.3. Оценки коэффициентов регрессии

Оценка коэффициента наклона:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}.$$

Оценка свободного члена:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

После этого нужно записать уравнение регрессии:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

4.4. Прогнозные значения и остатки

Для каждого наблюдения вычислить:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i,$$

$$e_i = y_i - \hat{y}_i.$$

Также рекомендуется вычислить e_i^2 и добавить этот столбец в расчётную таблицу.

4.5. Остаточная сумма квадратов

Остаточная сумма квадратов равна:

$$RSS = \sum_{i=1}^n e_i^2.$$

4.6. Оценка дисперсии случайной ошибки

Несмещённая оценка дисперсии ошибки:

$$s^2 = \frac{RSS}{n-2}.$$

Остаточное стандартное отклонение:

$$s = \sqrt{s^2}.$$

4.7. Стандартные ошибки коэффициентов

Стандартная ошибка коэффициента $\hat{\beta}_1$:

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}}.$$

Стандартная ошибка коэффициента $\hat{\beta}_0$:

$$SE(\hat{\beta}_0) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}.$$

4.8. Доверительные интервалы для коэффициентов

Для построения 95% доверительных интервалов используется критическое значение распределения Стьюдента:

$$t_{\text{кр}} = t_{1-\frac{\alpha}{2}; n-2},$$

где для 95% доверительного интервала

$$\alpha = 0.05.$$

Доверительный интервал для β_0 :

$$\hat{\beta}_0 - t_{\text{кр}} SE(\hat{\beta}_0) \leq \beta_0 \leq \hat{\beta}_0 + t_{\text{кр}} SE(\hat{\beta}_0).$$

Доверительный интервал для β_1 :

$$\hat{\beta}_1 - t_{\text{кр}} SE(\hat{\beta}_1) \leq \beta_1 \leq \hat{\beta}_1 + t_{\text{кр}} SE(\hat{\beta}_1).$$

Если доверительный интервал для β_1 не содержит ноль, то линейная зависимость между x и y считается статистически значимой на уровне значимости 5%.

4.9. Доверительный интервал для функции регрессии

Для произвольного значения x_0 оценка функции регрессии равна:

$$\hat{y}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Стандартная ошибка оценки средней функции регрессии:

$$SE_{\hat{y}}(x_0) = s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

95% доверительный интервал для средней функции регрессии:

$$\hat{y}(x_0) - t_{\text{кр}} SE_{\hat{y}}(x_0) \leq \mathbb{E}(Y \mid x_0) \leq \hat{y}(x_0) + t_{\text{кр}} SE_{\hat{y}}(x_0).$$

Для построения графика нужно взять набор значений x_0 на всём диапазоне наблюдаемых значений x . Для каждого x_0 нужно вычислить нижнюю и верхнюю границы интервала и изобразить их в системе координат.

4.10. Коэффициент детерминации

Общая сумма квадратов:

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2.$$

Остаточная сумма квадратов:

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Коэффициент детерминации:

$$R^2 = 1 - \frac{RSS}{TSS}.$$

Коэффициент R^2 показывает, какая доля изменчивости зависимой переменной y объясняется построенной линейной регрессионной моделью.

5. Требования к итоговому графику

На итоговом графике должны быть:

1. исходные точки (x_i, y_i) ;
2. оценённая прямая регрессии;
3. нижняя граница доверительного интервала для функции регрессии;
4. верхняя граница доверительного интервала для функции регрессии.

График должен иметь подписи осей, заголовок, легенду и координатную сетку.

6. Требования к отчёту

Отчёт должен содержать:

1. номер варианта;
2. таблицу исходных данных;
3. диаграмму рассеяния;
4. расчёт коэффициентов регрессии;
5. уравнение регрессии;
6. таблицу с прогнозными значениями и остатками;
7. расчёт остаточной дисперсии;
8. доверительные интервалы для коэффициентов;
9. график регрессии с доверительным интервалом для функции;
10. содержательные выводы.

7. Вопросы для вывода

В выводах необходимо ответить на вопросы:

1. Какой вид имеет полученное уравнение регрессии?
2. Является ли зависимость между x и y положительной или отрицательной?
3. Попадает ли ноль в доверительный интервал для коэффициента β_1 ?
4. Можно ли считать линейную зависимость статистически значимой?
5. В какой части графика доверительный интервал для функции регрессии наиболее узкий?
6. Как качество модели можно охарактеризовать по графику и по значению R^2 ?