Методы оптимизации

ИТМО, 2 курс, 4 семестр

Лекция №4
Численные методы безусловной оптимизации функции нескольких переменных

Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com

Релаксационная последовательность. Методы спуска

Как и для ФОП, в случае ФНП вводятся методы нулевого (прямые методы, методы прямого поиска), первого и второго порядка.

$$f(x) \to \min, x \in \mathbb{R}^n.$$

Примем целью построение следующей последовательности:

$$\left\{x^k\right\} : f_k = f\left(x^k\right) \le f\left(x^{k-1}\right) = f_{k-1},\ k = 1, 2, \ldots \qquad (*)$$

Если $f(x)$ ограничена снизу, то по теореме Вейерштрасса невозрастающая последовательность $\{f_k\}$ сходится к некоторому конечному пределу.
Однако соответствующая последовательность $\{x^k\}$ не обязательно сходится, а если сходится, то не обязательно к точке аналитического минимума x^*

Последовательность $\{x^k\}$, удовлетворяющая условию (*), называется **<u>релаксационной</u>**, а методы её построения – **<u>методами спуска</u>**.

Релаксационная последовательность. Методы спуска

$$\left\{x^k\right\}: f_k = f\left(x^k\right) \le f\left(x^{k-1}\right) = f_{k-1},\ k = 1, 2, \ldots \qquad (*)$$

Если $z = f(x, y)$: *при переходе от точки* (x^{k-1}, y^{k-1}) *к точке* (x^k, y^k)

спуск с линии уровня $z = f(x, y) = f_{k-1}$ *на линию уровня* $z = f(x, y) = f_k < f_{k-1}$.

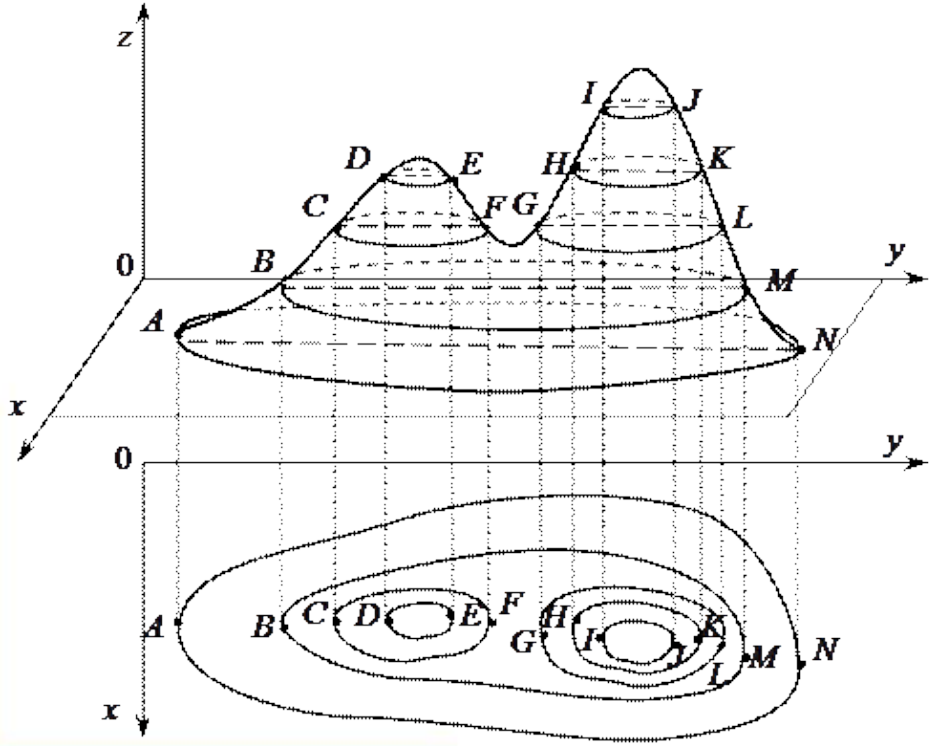

Сходится последовательность $\{f_k\}$ – **<u>слабая сходимость метода спуска</u>**; если сходится и соответствующая последовательность $\{x^k\}$, то **<u>сильная сходимость метода спуска</u>**.

Релаксационная последовательность. Методы спуска

Можно показать, что для сильно выпуклой дифференцируемой функции справедливы оценки, позволяющие делать выводы о сходимости:

$$\frac{f(\boldsymbol{x}^m)-f(\boldsymbol{x}^*)}{f(\boldsymbol{x}^0)-f(\boldsymbol{x}^*)} \leqslant \exp\left(-\gamma\sum_{k=1}^{m}\frac{f_{k-1}-f_k}{|\operatorname{grad} f(\boldsymbol{x}^{k-1})|^2}\right), \quad m\in\mathbb{N}.$$

$$\frac{|\boldsymbol{x}^m-\boldsymbol{x}^*|^2}{f(\boldsymbol{x}^0)-f(\boldsymbol{x}^*)} \leqslant \frac{2}{\gamma}\exp\left(-\gamma\sum_{k=1}^{m}\frac{f_{k-1}-f_k}{|\operatorname{grad} f(\boldsymbol{x}^{k-1})|^2}\right), \quad m\in\mathbb{N}.$$

<u>Рекомендуемый доп. материал: Аттетков, Галкин, Зарубин.djvu</u>

Релаксационная последовательность. Методы спуска

Условия для критерия останова:

$$|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}| < \varepsilon_1, \quad |f(\boldsymbol{x}^k) - f(\boldsymbol{x}^{k-1})| < \varepsilon_2,$$

$$|\operatorname{grad} f(\boldsymbol{x}^{k-1})| < \varepsilon_3, \quad \varepsilon_3 > 0.$$

Обозначения:

$$|x| \overset{def}{=} \|x\| = \{\textit{норма вектора } x\} \Rightarrow$$

$$\left|x^k - x^{k-1}\right| \overset{def}{=} \left\|x^k - x^{k-1}\right\|_2 = \{\textit{евклидова норма}\} = \sqrt{\left(x_1^k - x_1^{k-1}\right)^2 + \ldots + \left(x_n^k - x_n^{k-1}\right)^2},$$

$$\operatorname{grad} f(x) \equiv \nabla f(x) - \textit{вектор градиент функции } f \textit{ в точке } x.$$

Метод покоординатного спуска (метод 0-го порядка)

Здесь минимизация идёт циклами, по *n* шагов в каждом. Пусть $x^k=(x_1^k,x_2^k,\ldots,x_n^k)$.

- Фиксируем значения $x_2^k,\ldots,x_n^k$ и проводим минимизацию по переменной x_1. Получаем $(x_1^{k+1},x_2^k,\ldots,x_n^k)$, на этом первый шаг окончен.
- Фиксируем значения x_1^{k+1}, $x_3^k,\ldots,x_n^k$ и проводим минимизацию по переменной x_2. Получаем $(x_1^{k+1},x_2^{k+1}, x_3^k,\ldots,x_n^k)$.
- …
- Фиксируем значения x_1^{k+1},x_2^{k+1}, $x_3^{k+1},\ldots,x_{n-1}^{k+1}$ и проводим минимизацию по переменной x_n. Получаем $(x_1^{k+1},\ldots,x_n^{k+1})$.

Данный метод сводит задачу поиска наименьшего значения ФНП к многократному решению одномерных задач оптимизации. Для решения этих задач можно использовать любой известный метод, например, следующие методы : половинного деления, золотого сечения, хорд, Ньютона и т.д.

Метод покоординатного спуска

Минимизация ведется поочередно по направлениям, параллельным осям координат, потому **ломаная последовательных приближений** имеет **отрезки, параллельные ортам** (и каждый следующий перпендикулярен предыдущему).

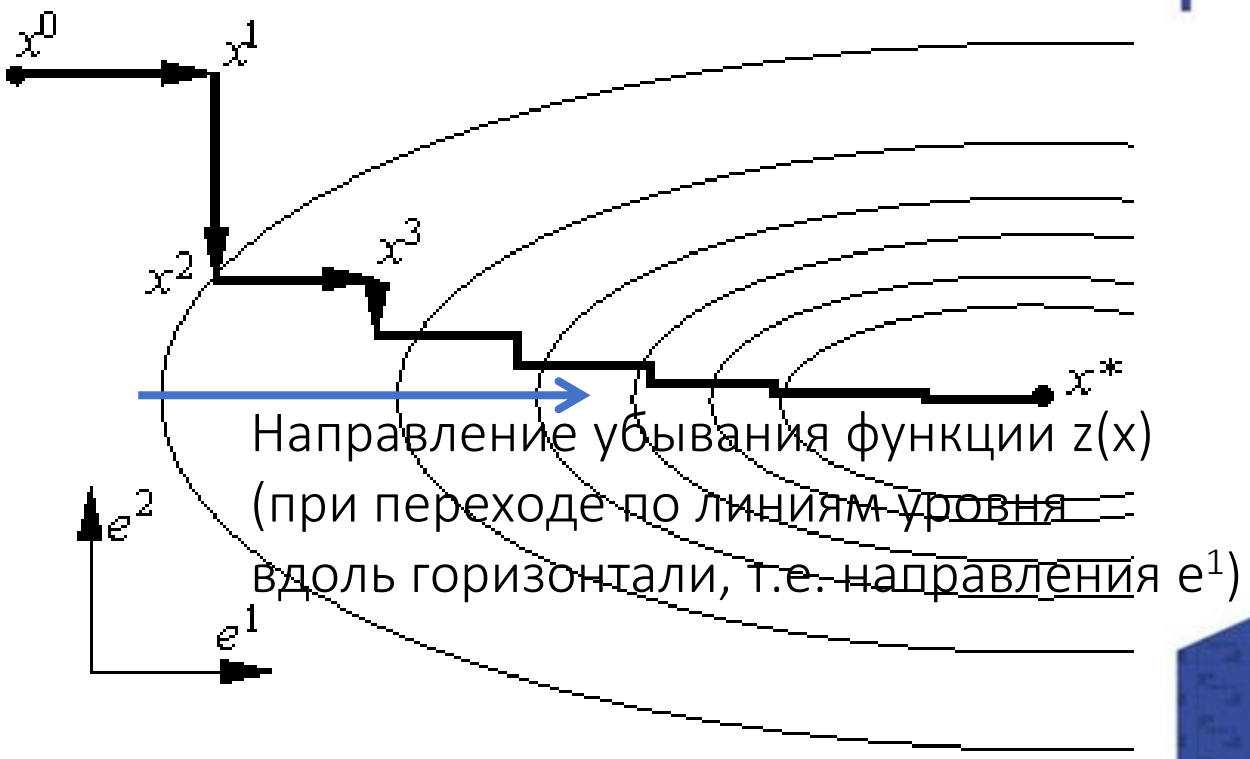

Нумерация приближений:
либо для каждого шага,
либо для каждого блока
(т.е. полной итерации)

Критерий останова: $\left\|x^k - x^{k-1}\right\| \le \varepsilon_1$ и/или $\left|f(x^k) - f(x^{k-1})\right| \le \varepsilon_2.$

Градиентные методы (методы 1-го порядка)

Методы 1-го порядка используют информацию о производной функции.
Если ограниченная снизу целевая функция f(x) является дифференцируемой на множестве R^n, то алгоритм поиска точки x^* ее минимума можно построить, используя информацию о градиенте этой функции.
Такие методы называются **<u>градиентными</u>**.

Градиентные методы безусловной оптимизации используют только первые производные целевой функции и являются методами линейной аппроксимации на каждом шаге, т. е. **<u>целевая функция на каждом шаге заменяется линейной моделью (поверхность заменяется касательной гиперплоскостью к ней в текущей точке)</u>**.

Во всех этих методах предполагается, что $f(x)$, grad$f$ существуют и непрерывны.

Градиентные методы (методы 1-го порядка)

3. Метод градиентного спуска. В природе мы нередко наблюдаем явления, сходные с решением задачи на нахождение минимума. К ним относится, в частности, стекание воды с берега котлована на дно. Упростим ситуацию, считая, что берега котлована «унимодальны», т. е. они гладкие и не содержат локальных углублений или выступов. Тогда вода устремится вниз в направлении наибольшей крутизны берега в каждой точке.

Градиентные методы (методы 1-го порядка)

Вектор градиент в точке показывает направление наибольшего возрастания функции (функция возрастает с максимальной скоростью).

В случае задачи минимизации и линейной аппроксимации противоположное направление (направление **антиградиента**) на каждой итерации выбирается как оптимальное (жадный алгоритм, т.е. локально оптимальный).
Длина шага в этом направлении определяется множителем η («эта»),
в машинном обучении его называют **скоростью обучения (learning rate)**,
чаще всего $\eta \in (0,1)$:

$$x^{k+1} = x^k - \eta \nabla f(x^k),$$ критерий останова: $$\|\nabla f(x)\| \le \varepsilon$$

Скорость обучения η уменьшают, если значение функции не уменьшается или растёт.
Можно сказать, что процесс завершается, если не существует величины шага, который приведёт к уменьшению значения функции.

Градиентный спуск: $x^{k+1} = x^k - \eta \nabla f(x^k)\big|_{\eta = const(k)}$

Диаграмма последовательных приближений и линий уровня

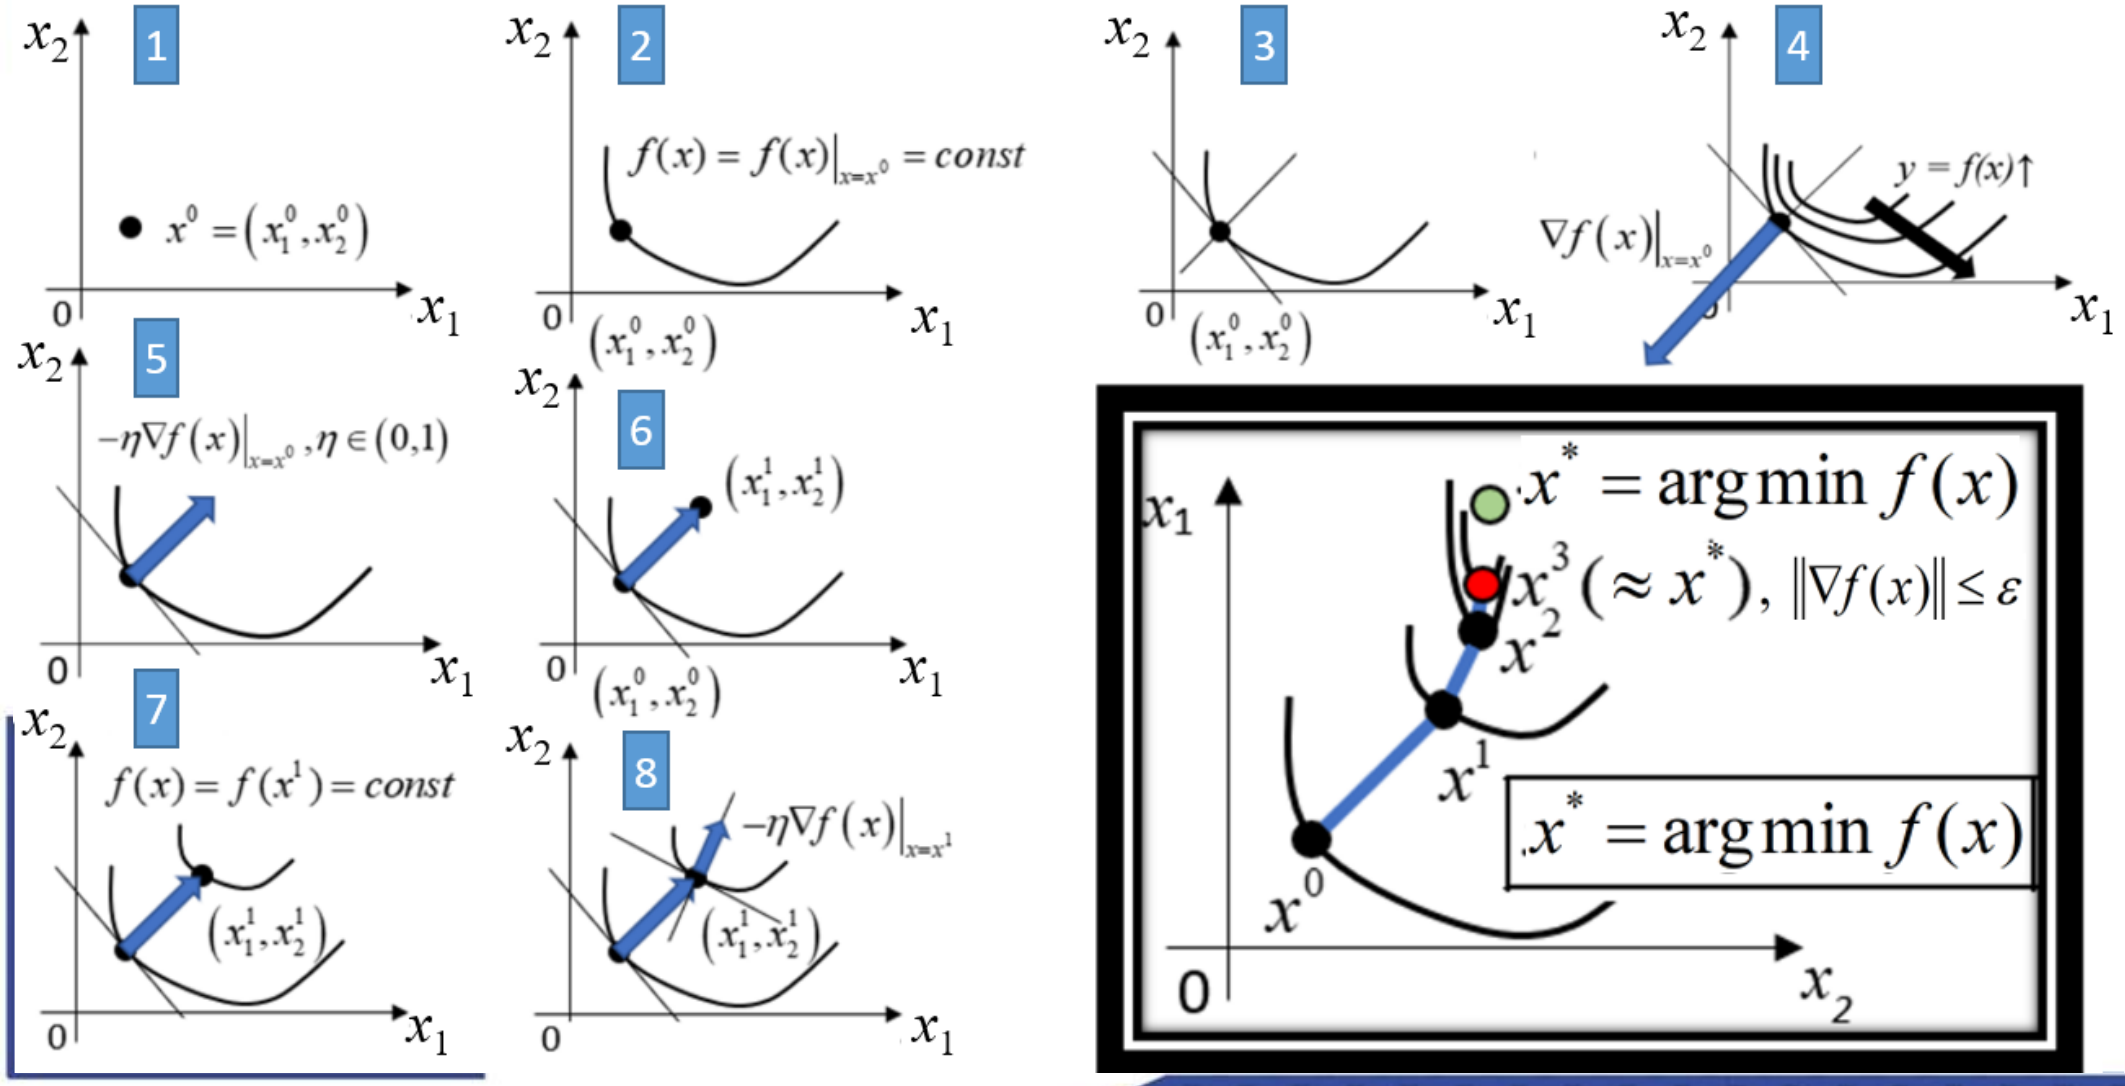

Градиентный спуск

Замечания:

1.Метод сходится медленно в случае оврагов.

Вдоль направлений, характеризующих «дно оврага», «овражная» функция меняется незначительно, а в других направлениях, характеризующих «склон оврага», происходит резкое изменение значений функции.

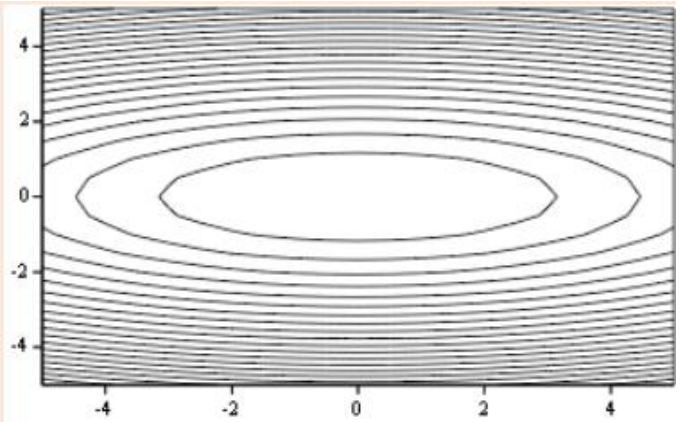

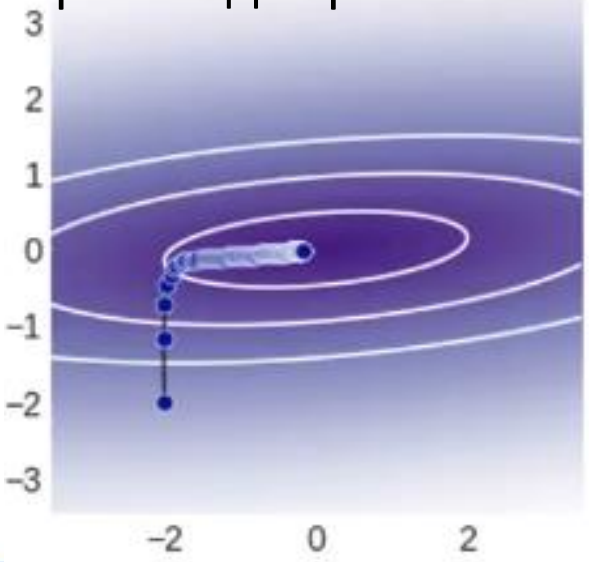

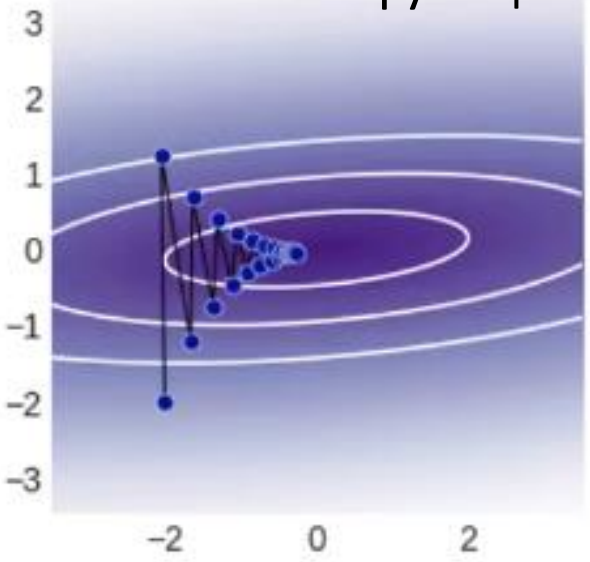

Масштабирование признаков в методах машинного обучения (или применить покоорд. спуск)

Градиентный спуск

Замечания:

2.Чувствителен к погрешностям вычислений (особенно сильно этот недостаток сказывается в малой окрестности точки минимума).

3.Может сходиться к седловой точке, «застревать в локальных минимумах», плохая сходимость для областей, где функция не явл. выпуклой.

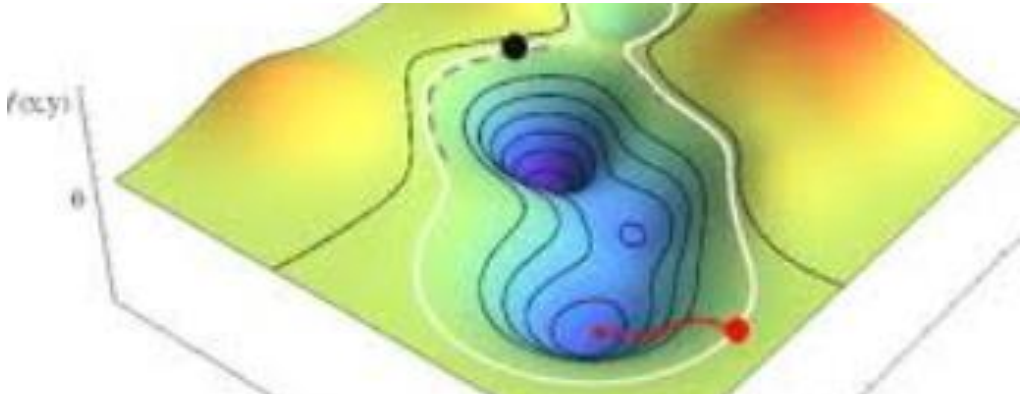

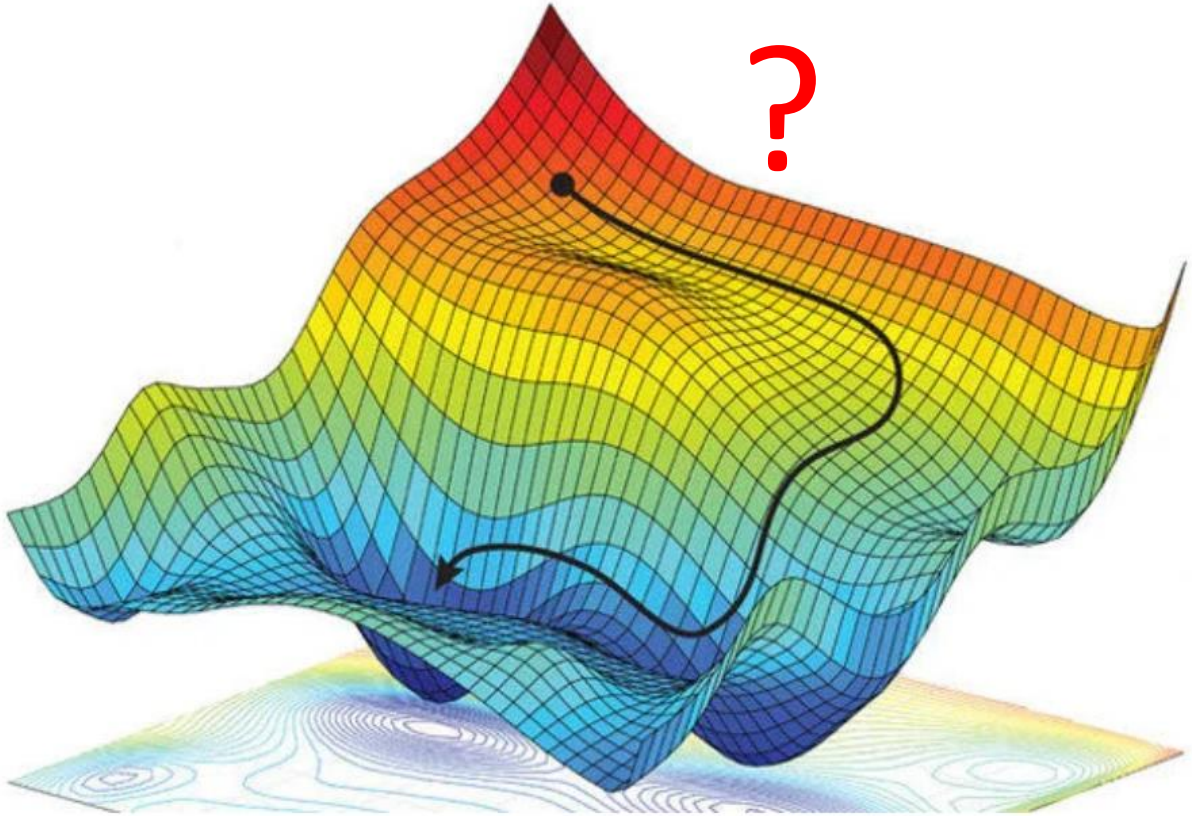

Метод наискорейшего спуска

Будем считать, что скорость обучения не является константой и может обновляться на каждой итерации. Есть варианты её обновления «по расписанию» (каждый m итераций), варьировать в зависимости от каких-то других критериев.

В полной мере «жадным алгоритмом» (=локально оптимальным) считается вариант, при котором делается наибольший возможный шаг (выбирается как можно большее η, *что обычно соответствует нескольким итерациям градиентного спуска*). Этот метод получил название **наискорейшего спуска**. Он требует на каждой итерации решать одномерную задачу оптимизации для выбора значения η.

Метод наискорейшего спуска

0. Даны непрерывно дифференцируемая функция $f(x)$, $\varepsilon>0$, $k = 0$.
1. Критерий останова: если $\left\|\nabla f(x^k)\right\| \le \varepsilon$, тогда переход на п.5.

2. Найти направление s^k – орт антиградиента:

$$s^k = -\frac{\nabla f(x^k)}{\left\|\nabla f(x^k)\right\|}.$$

3. Решить задачу одномерной оптимизации:

$$\eta_k = \arg\min_{\eta} f\left(x^k + \eta s^k\right).$$

4. Вычислить $x^{k+1} = x^k + \eta_k s^k$.

   Итерация: $k = k+1$. Переход на п.1.

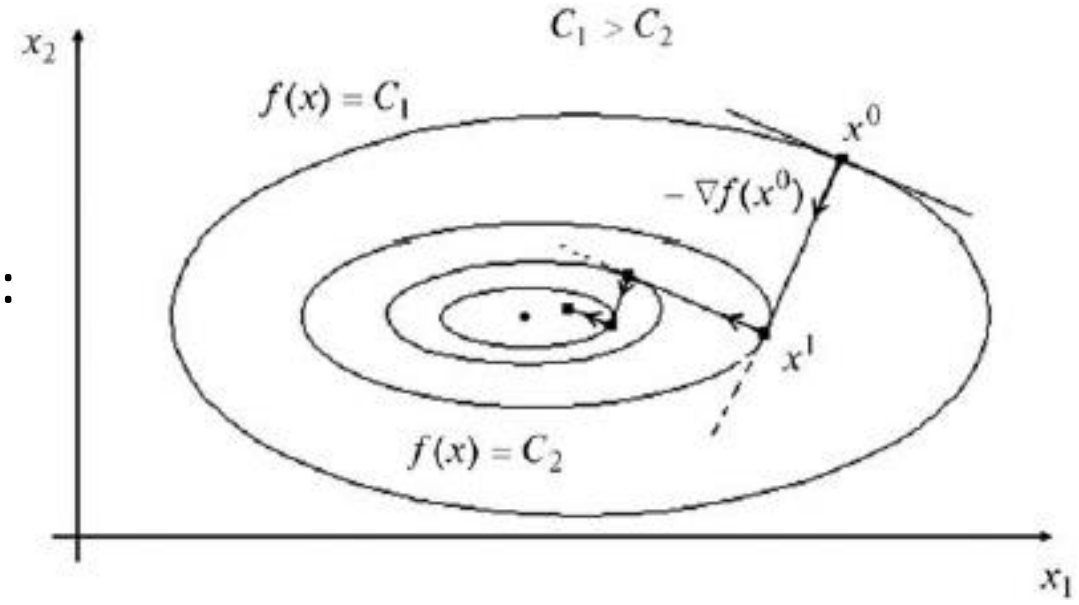

5. Принять $x^* = x^k$ – точка минимума, $y = f(x^k)$ – минимум. Конец.

Метод наискорейшего спуска

В записи метода удобно использовать орт антиградиента, однако на практике переписывают целевую функцию (ФНП) как функцию от η *(т.е. ФОП)*: *получают выражения для компонент решения через η и подставляют их в аналитическую запись f(x).*

И далее решают задачу оптимизации для полученной ФОП $g(\eta) = f(x)$.

Метод наискорейшего спуска

СКОРОСТЬ СХОДИМОСТИ

Оценки скорости сходимости получены только для сильно выпуклых функций, когда последовательность $\{x^k\}$ сходится к точке минимума функции $f(x)$ со скоростью геометрической прогрессии (линейная сходимость):

$$\| x^{k+1} - x^k \| \leq \frac{M - m}{M + m} \| x^k - x^* \|,$$

где M и m — оценки наибольшего и наименьшего собственных значений матрицы $H(x)$ функции $f(x)$ [29].

Метод Ньютона (метод 2-го порядка)

Решите оптимизационную задачу:

$$z(x, y) = \left(2x^2 + y^2\right)e^{-\left(x^2+y^2\right)} \to \min_{x,y\in\mathbb{R}}$$

Начальное приближение: (0.4, 0.4).

Критерий останова:

$$\left\|\nabla z(x, y)\right\| < 10^{-5}$$

Метод Ньютона (метод 2-го порядка)

Решите оптимизационную задачу:

$$z(x,y)=\left(2x^2+y^2\right)e^{-\left(x^2+y^2\right)}\to\min_{x,y\in\mathbb{R}}$$

Начальное приближение: (0.4, 0.4).

Критерий останова:

$$\left\|\nabla z(x,y)\right\|<10^{-5}$$

№	Стац. точка
1	(0,0)
2	(1,0)
3	(-1,0)
4	(0,-1)
5	(0,1)

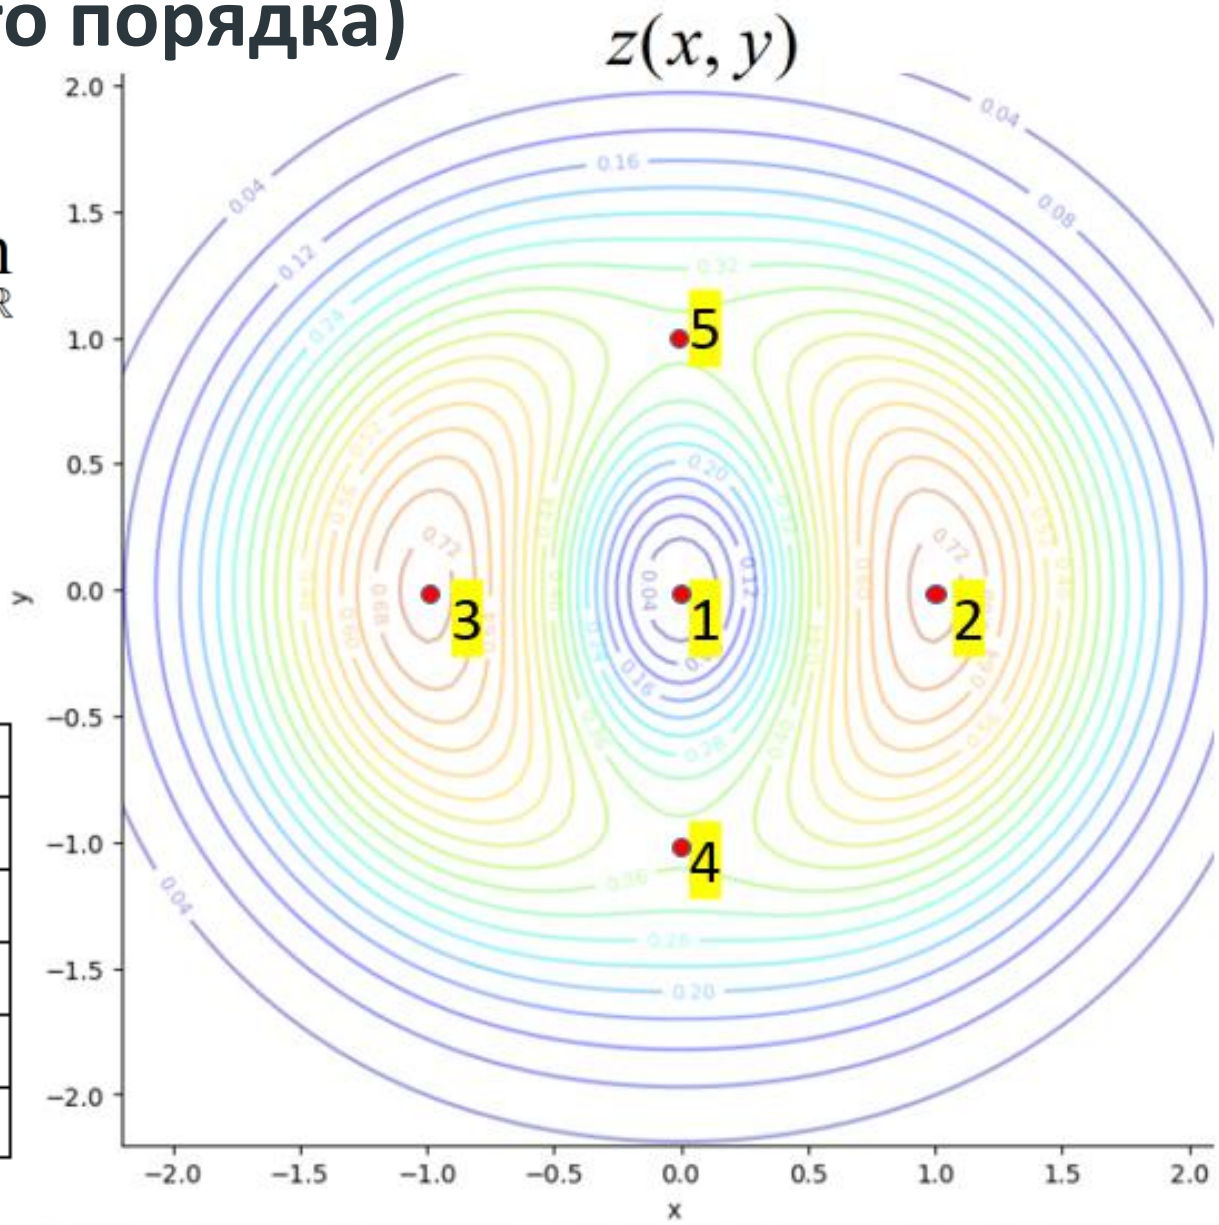

Метод Ньютона (метод 2-го порядка)

1. Mathematical Formulation

We want to minimize the function:

$z(x, y) = (2x^2 + y^2)e^{-(x^2+y^2)}$

Newton's Method for Optimization updates the parameters $\mathbf{x}_k = [x_k, y_k]^T$

$\mathbf{x}_{k+1} = \mathbf{x}_k - H^{-1}(\mathbf{x}_k)\nabla z(\mathbf{x}_k)$

where ∇z is the gradient vector and H is the Hessian matrix.

Gradient (∇z):

Using the product rule and chain rule:

$\frac{\partial z}{\partial x} = 2xe^{-(x^2+y^2)}(2 - 2x^2 - y^2)$

$\frac{\partial z}{\partial y} = 2ye^{-(x^2+y^2)}(1 - 2x^2 - y^2)$

Hessian (H):

The second-order partial derivatives are:

$\frac{\partial^2 z}{\partial x^2} = e^{-(x^2+y^2)}(4 - 20x^2 - 2y^2 + 8x^4 + 4x^2y^2)$

$\frac{\partial^2 z}{\partial y^2} = e^{-(x^2+y^2)}(2 - 4x^2 - 10y^2 + 8x^2y^2 + 4y^4)$

$\frac{\partial^2 z}{\partial x \partial y} = e^{-(x^2+y^2)}(-12xy + 8x^3y + 4xy^3)$

↓

Для случая ФОП:

$$f'(x) = f'(x^0) + f''(\xi)(x - x^0),$$

$$f'(x) \approx f'(x^0) + f''(x^0)(x - x^0) = 0, \text{ если } x = x^*$$

$$\Rightarrow x^{k+1} = x^k - \frac{f'(x^k)}{f''(x^k)}$$

$$(x, y)^{k+1} = (x, y)^k - \begin{pmatrix} \frac{\partial^2 z}{\partial x^2} & \frac{\partial^2 z}{\partial x \partial y} \\ \frac{\partial^2 z}{\partial x \partial y} & \frac{\partial^2 z}{\partial y^2} \end{pmatrix}^{-1} \cdot \begin{pmatrix} \frac{\partial z}{\partial x} \\ \frac{\partial z}{\partial y} \end{pmatrix}$$

Метод Ньютона (метод 2-го порядка)

Решите оптимизационную задачу:

$$z(x,y)=\left(2x^2+y^2\right)e^{-\left(x^2+y^2\right)} \to \min_{x,y\in\mathbb{R}}$$

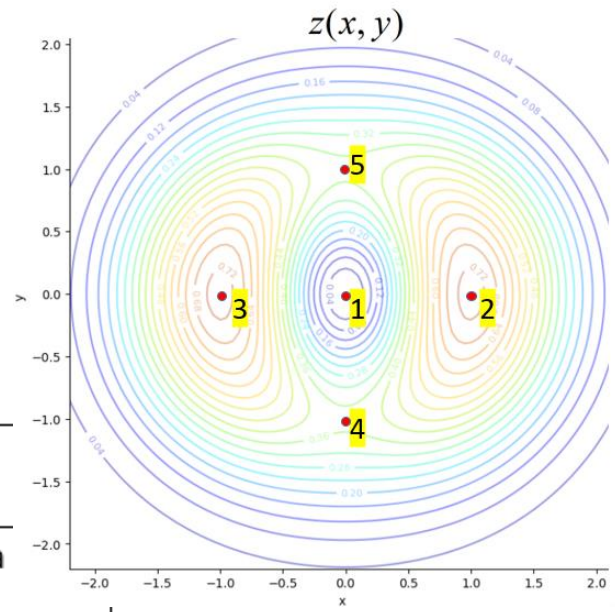

№	Стационарная точка	Гессиан	Свойство миноров, матрицы	Тип точки
1	(0,0)	$\begin{pmatrix} 4 & 0 \\ 0 & 2 \end{pmatrix}$	D1 > 0, D2 >0, Положительно определенная	Точка минимума
2	(1,0)	$\begin{pmatrix} -8/e & 0 \\ 0 & -2/e \end{pmatrix}$	D1 < 0, D2 >0, Отрицательно определенная	Точка максимума
3	(-1,0)	$\begin{pmatrix} -8/e & 0 \\ 0 & -2/e \end{pmatrix}$	D1 < 0, D2 >0, Отрицательно определенная	Точка максимума
4	(0,-1)	$\begin{pmatrix} 2/e & 0 \\ 0 & -4/e \end{pmatrix}$	D1 > 0, D2 < 0, Неопределенная	Седловая точка
5	(0,1)	$\begin{pmatrix} 2/e & 0 \\ 0 & -4/e \end{pmatrix}$	D1 > 0, D2 < 0, Неопределенная	Седловая точка

Метод Ньютона (метод 2-го порядка). Округление (артефакты)

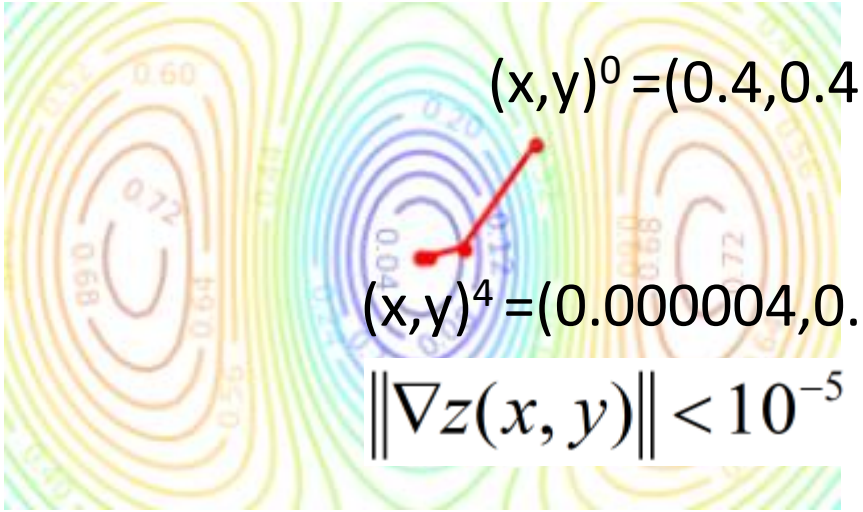

$$\|\nabla z(x,y)\| < 10^{-5}$$

Iteration	x	y	Gradient Norm
0	0.400000	0.400000	0.933192
1	0.146393	0.035523	0.276385
2	0.027663	0.003921	0.055635
3	0.001433	0.000133	0.002874
4	0.000004	0.000000	0.000008

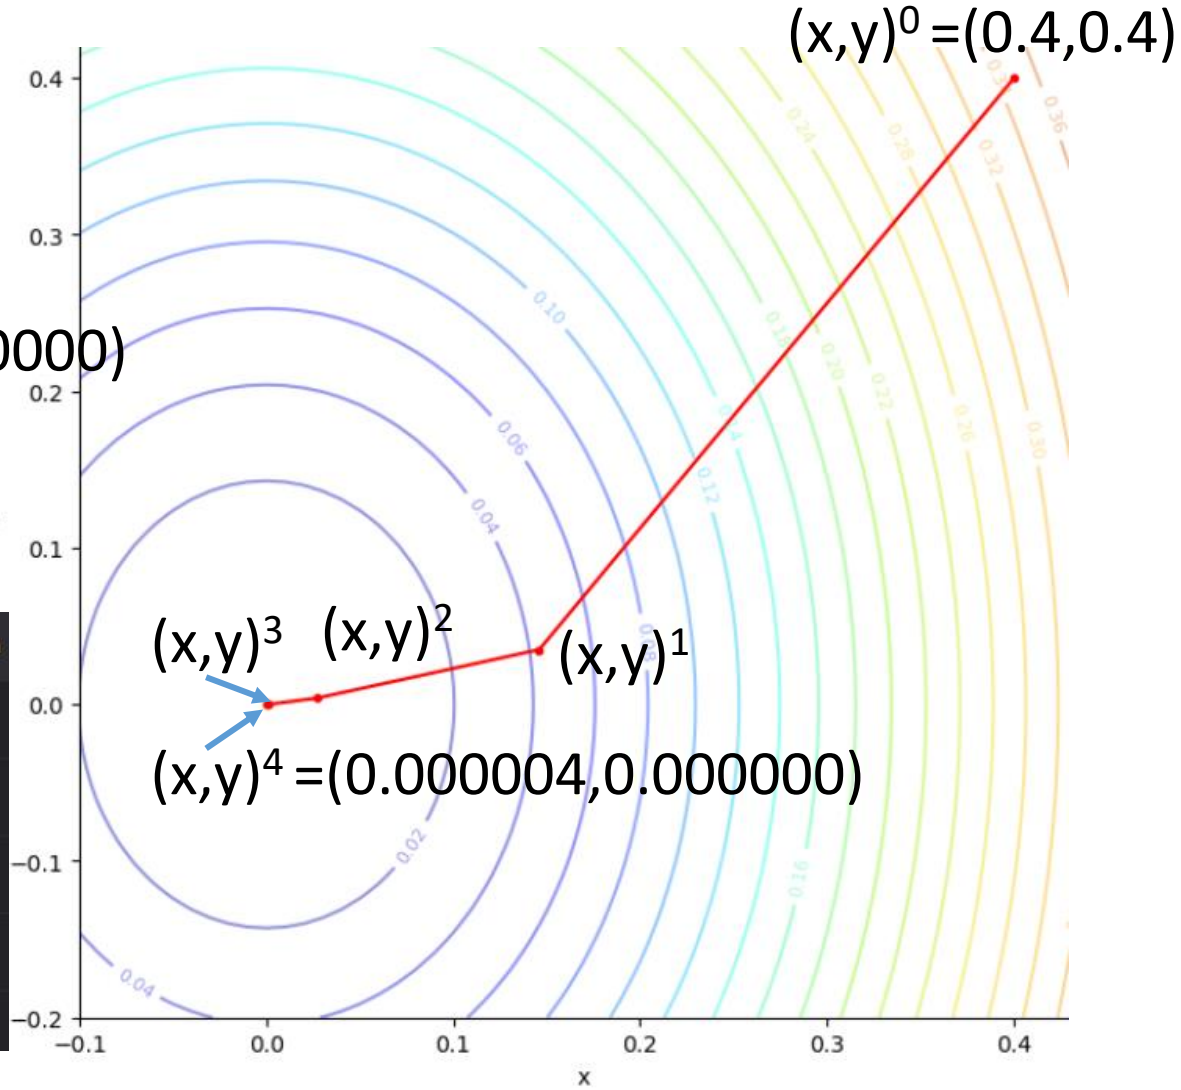

Метод Ньютона (метод 2-го порядка). Округление (артефакты)

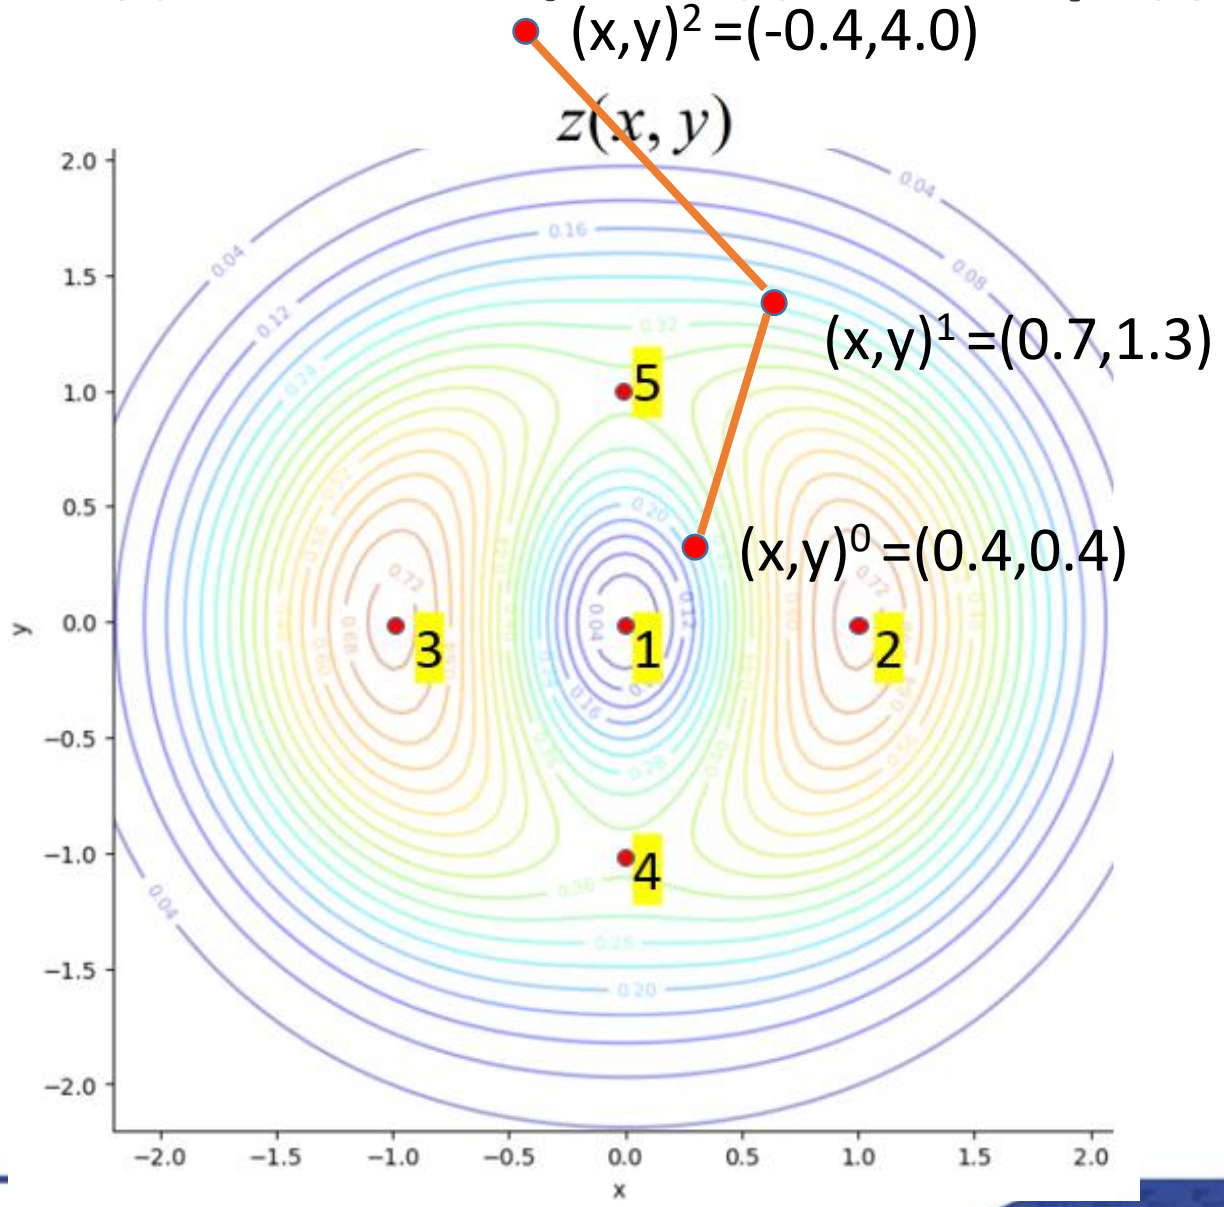

Последовательность приближений №2

Квазиньютоновские методы

<u>Цель:</u> Аппроксимировать обратный гессиан (матрицу, обратную к матрице Гессе)

Рассмотрим стандартную задачу гладкой безусловной оптимизации:

$$\min_{x \in \mathbb{R}^n} f(x), \tag{1.1}$$

где $f : \mathbb{R}^n \to \mathbb{R}$ — дважды непрерывно дифференцируемая функция.

Напомним, что методы спуска для решения задачи (1.1) итеративно выполняют обновления следующего вида:

$$x_{k+1} := x_k + \alpha_k d_k,$$

где $d_k \in \mathbb{R}^n$ — направление спуска для функции f в точке x_k, а $\alpha_k \geq 0$ — длина шага, настраиваемая с помощью линейного поиска.

Случай $d_k = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ соответствует[1] *методу Ньютона*. Как известно, метод Ньютона имеет хорошую скорость сходимости (по крайней мере, на финальной стадии своей работы), однако является слишком дорогостоящим — на каждой итерации метода нужно:

(a) вычислять матрицу-гессиан $\nabla^2 f(x_k)$;

(b) решать систему линейных уравнений $\nabla^2 f(x_k) d = -\nabla f(x_k)$ (для матриц $\nabla^2 f(x_k)$ общего вида сложность этой операции составляет $O(n^3)$).

Квазиньютоновские методы

Матрицы H_k в квазиньютоновских методах строятся следующим образом. На самой первой итерации выбирается некоторая начальная матрица $H_0 \in \mathbb{S}^n_{++}$ (обычно $H_0 = I_n$). Далее матрицы H_k обновляются в итерациях — на каждой итерации метода

(a) вычисляется новая точка $x_{k+1} := x_k - \alpha_k H_k \nabla f(x_k)$;

(b) выполняется обновление матрицы: $H_k \to H_{k+1}$.

Все квазиньютоновские методы отличаются между собой лишь способом обновления матрицы H_k. Напомним, что, согласно наложенным выше ограничениям, процедура обновления матрицы H_k должна быть достаточно эффективной: сложность этой процедуры должна составлять $O(n^2)$, и при этом не должно быть никаких вычислений гессиана. Таким образом, процедура обновления матрицы H_k должна каким-то эффективным образом «подгрузить» новую информацию о гессиане, при этом не вычисляя сам гессиан. Для этого используются градиенты $\nabla f(x_k)$ и $\nabla f(x_{k+1})$, а также следующее правило.

Квазиньютоновское правило

Выбрать новую матрицу H_{k+1} таким образом, чтобы выполнялось *уравнение секущей*:

$$H_{k+1}[\nabla f(x_{k+1}) - \nabla f(x_k)] = x_{k+1} - x_k. \tag{1.2}$$

Квазиньютоновские методы

Наиболее популярные схемы обновления квазиньютоновских матриц

Обозначим $s_k := x_{k+1} - x_k$ и $y_k := \nabla f(x_{k+1}) - \nabla f(x_k)$. Любая из следующих схем обновления матрицы H_k гарантирует выполнение уравнения секущей (1.2).

(a) *Симметричная коррекция ранга 1* (SR1):

$$H_{k+1} = H_k + \frac{(s_k - H_k y_k)(s_k - H_k y_k)^T}{\langle s_k - H_k y_k, y_k \rangle}.$$

(b) *Схема Давидона–Флетчера–Пауэлла* (DFP):

$$H_{k+1} = H_k - \frac{H_k y_k y_k^T H_k}{\langle H_k y_k, y_k \rangle} + \frac{s_k s_k^T}{\langle y_k, s_k \rangle}.$$

(c) *Схема Бройдена–Флетчера–Гольдфарба–Шанно* (BFGS):

В ЛР5!

$$H_{k+1} = \left(I_n - \frac{s_k y_k^T}{\langle y_k, s_k \rangle} \right) H_k \left(I_n - \frac{y_k s_k^T}{\langle y_k, s_k \rangle} \right) + \frac{s_k s_k^T}{\langle y_k, s_k \rangle}.$$

Наиболее эффективной и стабильной схемой считается BFGS.

Квазиньютоновские методы

Замечания (без доказательства, практико-ориентированные выводы):

1. Это методы первого порядка (не требуется вторая производная, меньше вычислений с плавающей точкой и т.д.).
2. Скорость сходимости – сверхлинейная (может быть и квадратичная).
3. Смысл итераций: метод секущих (=хорд) для решения системы уравнений grad$f(x)$=0 (n уравнений).
4. Для каждой из n функций в системе grad$f(x)$=0 найдём частную производную (по каждой из n переменных), чтоб запустить метод первого порядка для решения уравнений – получим матрицу Якоби.
5. Эта матрица Якоби (как и матрица Гессе ИСХОДНОЙ функции) является симметричной.
6. Аппроксимируется обратная матрица Гессе на каждой итерации или сама матрица Гессе – модель будет симметричной положительно определенной матрицей.

Спасибо за внимание!
Вступайте в группу по дисциплине!

Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com